

Tecnológico de Monterrey

Soccer Play Prediction

Avance 3. Baseline

Alumnos:

José Antonio Fernández Pérez	A01795991
Juan José Ponce	A01659811
Hiram García Austria	A00378771

Avance 3 Baseline para la predicción de posiciones de jugadores

Índice

1 Objetivo y alcance 1
2 Datos y preparación 1
Separación de los datos 2
3 Selección del algoritmo 3
Referencias simples 3
4 Características y análisis de relevancia 3
Importancia por permutación 4
Comparación de grupos de características 5
5 Métricas y resultados 6
Resultados en partidos de prueba 6
6 Análisis de subajuste y sobreajuste 7
7 Desempeño mínimo y evaluación de viabilidad 9
8 Conclusiones 10
Referencias 11

Índice de tablas

Tabla 1. Distribución de partidos y ejemplos elegibles 2
Tabla 2. Configuración seleccionada del Random Forest 3
Tabla 3. Importancia por permutación a un segundo 4
Tabla 4. Comparación de características en validación 6
Tabla 5. Resultados de los modelos en prueba 6
Tabla 6. Evaluación del Random Forest entre conjuntos 8
Tabla 7. Comparación con el desempeño mínimo 9

Objetivo y alcance

En este avance construimos y evaluamos un modelo de referencia para predecir posiciones futuras de jugadores de fútbol mediante tracking. Comparamos un Random Forest de regresión con dos referencias simples: persistencia y velocidad constante. El propósito es establecer medidas de calidad y una referencia reproducible para evaluar posteriormente modelos que representen explícitamente las interacciones espaciales y su evolución temporal.

El Random Forest superó a velocidad constante en los tres horizontes. A un segundo obtuvo un error medio de 0.635 m, frente a 0.724 m de velocidad constante. Los resultados corresponden a dos partidos completos reservados como conjunto de prueba, sobre ejemplos elegibles de juego activo.

Delimitamos el objetivo a movimiento individual observado. El modelo no clasifica jugadas ni recomienda decisiones tácticas. Esta delimitación permite evaluar viabilidad predictiva con los datos disponibles antes de incorporar representaciones de jugadas completas y estadísticas históricas de jugadores.

Datos y preparación

Utilizamos los diez archivos de partidos disponibles en la carpeta Datos. Cada archivo contiene un Parquet de tracking. En conjunto se leyeron 33,480,918 filas. Los metadatos de los archivos indican muestreo a 25 Hz y coordenadas en metros, con origen en el centro del campo.

Verificamos la identidad mediante entity_id y la pertenencia al equipo mediante team_id. La clave de observación utilizada fue periodo, frame e identidad de la entidad, dentro de cada partido. Excluimos todas las filas pertenecientes a claves duplicadas, sin elegir arbitrariamente una observación: 17,424 filas quedaron fuera de la construcción de ejemplos. Después se excluyeron 12,892,181 filas adicionales por ausencia de coordenadas o tiempo finitos, o por no estar el balón en juego. Este último conteo incluye pausas válidas del partido y no representa únicamente errores del dataset.

Dividimos cada trayectoria en segmentos continuos. Una diferencia temporal fuera del intervalo de 0.02 a 0.06 segundos inició un segmento nuevo. Construimos ejemplos solo cuando la historia requerida y los tres objetivos futuros pertenecían al mismo segmento y periodo. Las ventanas no atraviesan las pausas detectadas por estas reglas.

Tomamos un ancla cada dos segundos del reloj de frames y utilizamos posiciones pasadas de 0.2 y 0.4 segundos. Los horizontes evaluados fueron 0.52, 1 y 2 segundos. El primero representa aproximadamente medio segundo y corresponde a 13 observaciones a 25 Hz; se utilizó una observación existente, sin interpolar un

objetivo a 0.50 segundos. Además de unir por frame, comprobamos las diferencias del tiempo registrado con una tolerancia de 0.012 segundos.

Recalculamos velocidades y aceleraciones con diferencias hacia atrás, sin utilizar las velocidades provistas en el archivo. Así, las características de movimiento utilizan únicamente observaciones disponibles hasta el instante de predicción. Cuando el equipo atacaba hacia el eje horizontal negativo, rotamos 180 grados posiciones, velocidades, aceleraciones, desplazamientos relativos y objetivos. No normalizamos cada jugador de forma independiente.

La información del balón se incorporó en el instante actual. Si faltaba su posición, asignamos cero a su desplazamiento relativo y activamos un indicador de ausencia. Los ejemplos sin características u objetivos numéricos finitos se excluyeron. No se utilizaron nombres, dorsales ni identificadores como predictores.

Separación de los datos
Separamos partidos completos antes del ajuste de modelos. La asignación siguió el orden de los nombres de archivo, que comienzan con la fecha del partido. Dentro de una misma fecha, el orden es alfabético y no supone un orden real de inicio de los encuentros.

Tabla 1. Distribución de partidos y ejemplos elegibles

Conjunto	Partidos	Ejemplos elegibles
Entrenamiento	GENOA-NAPOLI; INTER-MONZA; PARMA-CAGLIARI; UDINESE-COMO; ATALANTA-SASSUOLO; FROSINONE-JUVENTUS	221,248
Validación	TORINO-MILAN; VENEZIA-LECCE	70,510
Prueba	BOLOGNA-LAZIO; ROMA-FIORENTINA	64,636

Fuente: Elaboración propia con los datos del proyecto.

Para limitar el costo de entrenamiento seleccionamos aleatoriamente 12,000 ejemplos de cada partido de entrenamiento, con semilla 52: 72,000 ejemplos en total. Validación y prueba utilizaron todos sus ejemplos elegibles, 70,510 y 64,636, respectivamente. Las comparaciones de los tres modelos utilizan exactamente los mismos ejemplos en cada conjunto.

La separación evita compartir instantes de un mismo partido entre entrenamiento y prueba. Sin embargo, jugadores, equipos y ventanas dentro de un partido no son observaciones estadísticamente independientes. Por ello, los tamaños de muestra

se interpretan como ejemplos de predicción y no como un número equivalente de partidos independientes.

Selección del algoritmo

Seleccionamos Random Forest de regresión porque las variables son estructuradas, la relación entre movimiento y posición futura puede ser no lineal y necesitamos inspeccionar la contribución de las características. El algoritmo combina árboles de regresión y admite múltiples salidas; controlamos su complejidad mediante profundidad máxima y tamaño mínimo de hoja (scikit-learn developers, s. f.-b).

Entrenamos un modelo por horizonte para predecir el desplazamiento horizontal y vertical. La posición futura se reconstruye sumando el desplazamiento predicho a la posición actual. Se emplearon 80 árboles, muestreo bootstrap, todas las características disponibles en cada búsqueda de división y semilla 52. Comparamos dos configuraciones: profundidad 12 y mínimo de 20 ejemplos por hoja; y profundidad 20 y mínimo de 5. Elegimos por horizonte la configuración con menor error medio en validación, sin seleccionar parámetros con el conjunto de prueba.

Tabla 2. Configuración seleccionada del Random Forest

Horizonte s	Árboles	Profundidad máxima	Mínimo por hoja
0.52	80	20	5
1.00	80	20	5
2.00	80	20	5

Fuente: Elaboración propia con los datos del proyecto.

Los árboles no requieren estandarización para comparar umbrales. No aplicamos PCA: las 13 variables tienen interpretación física y conservar sus unidades facilita analizar el baseline. En esta etapa priorizamos inspección predictiva y comparación experimental de grupos de características.

Referencias simples

Persistencia predice un desplazamiento nulo. Velocidad constante predice el desplazamiento como la velocidad estimada durante los últimos 0.2 segundos multiplicada por el horizonte. Ambas referencias se calculan sin entrenamiento. Su comparación es más pertinente para esta regresión que un predictor aleatorio, porque establecen cuánto aporta aprender de los datos respecto de reglas físicas sencillas.

Características y análisis de relevancia

El modelo completo utilizó 13 características: posición actual x e y; velocidades horizontales y verticales calculadas sobre 0.2 y 0.4 segundos; dos componentes de

aceleración; dos componentes del desplazamiento relativo al balón; indicador de balón ausente; distancia al compañero más cercano; y distancia al rival más cercano. Las distancias entre jugadores se calcularon usando únicamente sus posiciones observadas en el instante actual.

No incorporamos isCarrier, porque es una estimación obtenida mediante posesión de equipo, proximidad y un umbral de 1.5 m. Tampoco agregamos tasas de pases o tiros sin una fuente de eventos vinculada y anterior al momento evaluado. El análisis mide el aporte de las características disponibles, sin atribuir capacidades técnicas no observadas a los jugadores.

Importancia por permutación
Aplicamos importancia por permutación sobre 5,000 ejemplos de validación seleccionados con semilla 52. Permutamos cada característica tres veces y medimos el aumento del error medio en metros. Un incremento positivo indica que alterar esa variable perjudica al modelo; valores cercanos a cero indican escasa dependencia dentro de esta configuración. La importancia corresponde al modelo ajustado, puede verse afectada por correlación entre variables y no demuestra causalidad (scikit-learn developers, s. f.-a).

La siguiente tabla presenta los resultados a un segundo. La desviación estándar corresponde a las tres permutaciones y no es un intervalo de confianza sobre partidos.

Tabla 3. Importancia por permutación a un segundo

Característica	Aumento del error m	Desviación estándar m
vx_02	1.67719	0.00872
vy_02	1.13247	0.00790
ax	0.09498	0.00049
ay	0.05834	0.00038
x	0.00454	0.00028
vy_04	0.00348	0.00020
y	0.00314	0.00023
vx_04	0.00189	0.00006
ball_dx	0.00149	0.00012

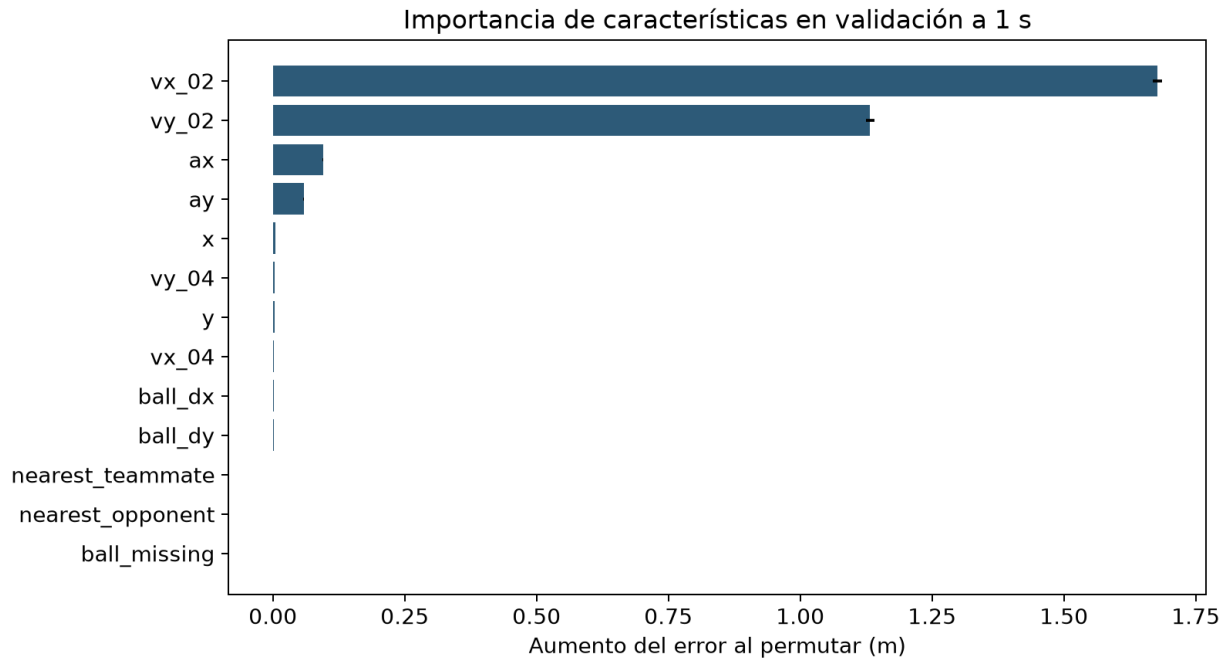
Característica	Aumento del error m	Desviación estándar m
ball_dy	0.00148	0.00011
nearest_teammate	0.00105	0.00010
nearest_opponent	0.00036	0.00042
ball_missing	-0.00002	0.00000

Fuente: Elaboración propia con los datos del proyecto.

Las variables con mayor importancia fueron las velocidades horizontal y vertical de los últimos 0.2 segundos y la aceleración horizontal. Su posición en el análisis permite identificar qué información utiliza el modelo para anticipar desplazamientos. Una importancia pequeña de las distancias no implica que las interacciones carezcan de valor táctico: esta representación solo incluye distancias mínimas, sin conservar la estructura completa de jugadores y relaciones.

Figura 1

Importancia de características en validación a un segundo



Nota. **Elaboración propia. Las barras de error representan la desviación estándar de tres permutaciones.**

Comparación de grupos de características

Comparamos el modelo completo con otro que utiliza exclusivamente las ocho variables de posición y movimiento propio. Se mantuvieron los parámetros

seleccionados y el conjunto de entrenamiento. La comparación se realizó en validación; los porcentajes positivos representan reducción de error al añadir contexto.

Tabla 4. Comparación de características en validación

Horizonte s	Movimiento propio m	Con contexto m	Mejora relativa
0.52	0.273	0.272	0.26 %
1.00	0.717	0.714	0.50 %
2.00	2.060	2.045	0.71 %

Fuente: Elaboración propia con los datos del proyecto.

El contexto espacial simplificado mejoró el error de validación entre 0.26 % y 0.71 %. Su aporte fue pequeño frente al movimiento propio. Esto no demuestra que las interacciones carezcan de valor táctico: las distancias mínimas solo representan una parte de ellas. El modelo completo quedó establecido como el candidato principal; la comparación reducida se utiliza como diagnóstico y no como una nueva búsqueda sobre prueba.

Métricas y resultados

La métrica principal fue el error euclidiano de posición futura en metros. Para cada ejemplo calculamos la distancia entre la posición predicha y la observada, y promediamos esas distancias. Esta medida expresa directamente cuánto se aleja la predicción de la ubicación registrada, lo que permite interpretar el resultado en términos espaciales.

Complementamos el promedio con mediana y percentil 90. La mediana describe un caso central y el percentil 90 muestra una magnitud de error que no supera el 90 % de los ejemplos. Para analizar ajuste también calculamos la raíz del promedio del error de distancia al cuadrado, que penaliza más los errores altos. Cada horizonte evalúa un punto futuro; por ello no presentamos estos resultados como ADE de una trayectoria completa.

Resultados en partidos de prueba

Tabla 5. Resultados de los modelos en prueba

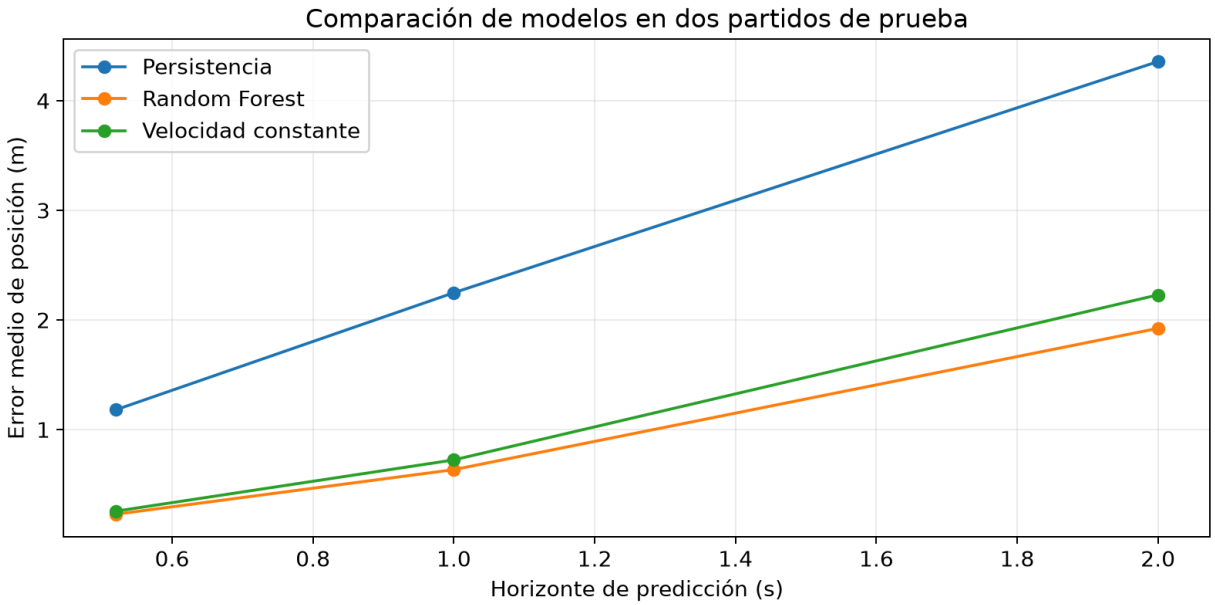
Horizonte (s)	Modelo	Error medio (m)	Mediana (m)	Percentil 90 (m)
0.52	Persistencia	1.181	0.969	2.231

Horizonte (s)	Modelo	Error medio (m)	Mediana (m)	Percentil 90 (m)
0.52	Velocidad constante	0.256	0.186	0.548
0.52	Random Forest	0.228	0.173	0.470
1.00	Persistencia	2.249	1.855	4.250
1.00	Velocidad constante	0.724	0.529	1.573
1.00	Random Forest	0.635	0.480	1.323
2.00	Persistencia	4.357	3.635	8.223
2.00	Velocidad constante	2.229	1.698	4.729
2.00	Random Forest	1.924	1.512	3.937

Fuente: Elaboración propia con los datos del proyecto.

Figura 2

Comparación de modelos en dos partidos de prueba



Nota. **Elaboración propia.**

La evolución del error con el horizonte refleja la dificultad de extrapolar cambios de movimiento. Los promedios resumen todos los ejemplos elegibles de prueba; el archivo de resultados conserva adicionalmente el desglose por partido para revisar si la comparación se sostiene en ambos encuentros.

6 Análisis de subajuste y sobreajuste

Comparamos las métricas del Random Forest en la muestra efectiva de entrenamiento, validación y prueba. Los conjuntos de evaluación no se utilizaron para ajustar los árboles; validación se utilizó únicamente para seleccionar entre las dos configuraciones.

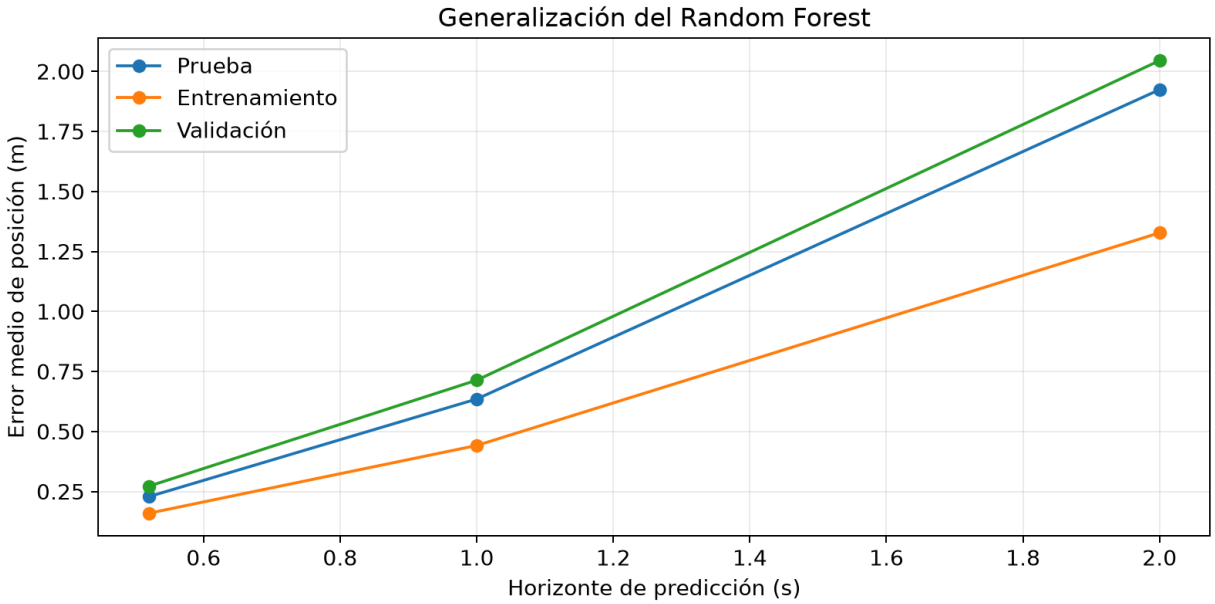
Tabla 6. Evaluación del Random Forest entre conjuntos

Horizonte (s)	Conjunto	Error medio (m)	Raíz del error cuadrático (m)	Percentil 90 (m)
0.52	Entrenamiento	0.159	0.216	0.332
0.52	Validación	0.272	0.376	0.565
0.52	Prueba	0.228	0.300	0.470
1.00	Entrenamiento	0.442	0.591	0.930
1.00	Validación	0.714	0.944	1.497
1.00	Prueba	0.635	0.828	1.323
2.00	Entrenamiento	1.328	1.716	2.756
2.00	Validación	2.045	2.592	4.192
2.00	Prueba	1.924	2.442	3.937

Fuente: Elaboración propia con los datos del proyecto.

Figura 3

Generalización del Random Forest



Nota. **Elaboración propia.**

A 0.52 s, el error medio pasó de 0.159 m en entrenamiento a 0.272 m en validación y 0.228 m en prueba. La brecha entre entrenamiento y validación fue de 0.113 m (70.8 %). A 1.00 s, el error medio pasó de 0.442 m en entrenamiento a 0.714 m en validación y 0.635 m en prueba. La brecha entre entrenamiento y validación fue de 0.272 m (61.6 %). A 2.00 s, el error medio pasó de 1.328 m en entrenamiento a 2.045 m en validación y 1.924 m en prueba. La brecha entre entrenamiento y validación fue de 0.718 m (54.0 %).

El error menor en entrenamiento muestra señales de sobreajuste. Sin embargo, el modelo conserva su ventaja frente a las dos referencias simples en validación y prueba, por lo que el sobreajuste no elimina el valor predictivo observado. Tampoco encontramos un patrón claro de subajuste severo: el modelo aprende relaciones que reducen el error fuera de entrenamiento. Las diferencias entre partidos pueden contribuir a las brechas, y no es posible separar completamente ambas causas con esta partición. Controlar la complejidad y ampliar la evaluación por partidos son acciones pertinentes para la siguiente iteración.

Desempeño mínimo y evaluación de viabilidad

Establecimos como criterio operativo del experimento que el modelo aprendido reduzca el error medio frente a la mejor referencia simple en validación y que esa ventaja se mantenga en prueba, revisando cada horizonte por separado. El umbral se define de forma relativa porque no existe en este proyecto un histórico

comparable ni una tolerancia espacial de uso táctico acordada con el sponsor. No sería justificable declarar un error absoluto aceptable sin esa definición.

En esta evaluación, velocidad constante es la referencia física utilizada en la siguiente comparación. La mejora relativa se calculó como cien por la diferencia entre el error de referencia y el del Random Forest, dividida entre el error de referencia. Un porcentaje negativo indica deterioro.

Tabla 7. Comparación con el desempeño mínimo

Tiempo (s)	Vel. const. validación (m)	RF validación (m)	Vel. const. prueba (m)	RF prueba (m)	Mejora en prueba
0.52	0.289	0.272	0.256	0.228	10.87 %
1.00	0.769	0.714	0.724	0.635	12.28 %
2.00	2.283	2.045	2.229	1.924	13.70 %

Fuente: Elaboración propia con los datos del proyecto.

El Random Forest cumplió el criterio de mejora frente a la mejor referencia simple en validación y prueba para los tres horizontes. La ventaja se mantuvo también en cada uno de los dos partidos de prueba. Las mejoras son descriptivas; esta ejecución no establece significación estadística entre partidos.

El cumplimiento constituye evidencia de viabilidad para la predicción de posiciones dentro del alcance evaluado. No demuestra por sí mismo utilidad táctica, generalización a otras temporadas ni superioridad frente a arquitecturas espaciotemporales. Dos partidos de prueba permiten una primera comprobación fuera de entrenamiento, pero todavía ofrecen cobertura limitada de contextos competitivos.

Conclusiones

Construimos un baseline reproducible con datos de diez partidos, objetivos futuros observados, características calculadas con historia pasada y evaluación en partidos separados. La comparación entre persistencia, velocidad constante y Random Forest establece una referencia concreta para el siguiente ciclo del proyecto.

El Random Forest superó a velocidad constante en los tres horizontes. Las mejoras relativas frente a velocidad constante fueron 10.87 %, 12.28 % y 13.70 % para 0.52, 1 y 2 segundos, respectivamente. Estos resultados deben conservarse como referencia experimental para evaluar cambios posteriores.

El análisis de importancia identifica las variables que el modelo utiliza y la comparación por grupos permite valorar el aporte del contexto espacial

simplificado. Las diferencias entre entrenamiento y evaluación muestran por qué no basta con reportar el ajuste sobre los datos utilizados para aprender.

El siguiente paso es evaluar una representación que conserve las relaciones entre jugadores y balón a lo largo del tiempo. Una GNN con componente temporal deberá demostrar mejora sobre estas referencias bajo la misma separación de partidos y las mismas métricas. Los perfiles históricos de pase, tiro y velocidad podrán incorporarse cuando exista una fuente compatible, manteniendo únicamente información disponible antes del instante de predicción.

La preparación, el registro de decisiones, los controles de calidad y la evaluación forman parte del aseguramiento de calidad del ciclo CRISP-ML(Q) (Visengeriyeva et al., 2023). Se conservaron el programa de ejecución, los ejemplos derivados, las métricas, la selección de parámetros y las gráficas para permitir revisión y reproducción.

Referencias

scikit-learn developers. (s. f.-a). *Permutation feature importance*. scikit-learn. https://scikit-learn.org/stable/modules/permutation_importance.html

scikit-learn developers. (s. f.-b). *RandomForestRegressor*. scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestRegressor.html

Visengeriyeva, L., Kammer, A., Bär, I., Kniesz, A., & Plöd, M. (2023). *CRISP-ML(Q): The ML lifecycle process*. MLOps. INNOQ. https://ml-ops.org/content/crisp-ml