



# Tecnológico de Monterrey

## Soccer Play Prediction

*Avance 1. Análisis exploratorio de datos*

### Alumnos:

|                              |           |
|------------------------------|-----------|
| José Antonio Fernández Pérez | A01795991 |
| Juan José Ponce              | A01659811 |
| Hiram García Austria         | A00378771 |

## **Resumen**

Este avance presenta el diagnóstico documentado de las muestras disponibles y una propuesta de modelado para el proyecto de predicción de jugadas y simulación de respuestas tácticas en el fútbol italiano.

El conjunto completo todavía no se encuentra disponible y los ejemplos recibidos presentan limitaciones de integridad, identificación y sincronización. Por ello, la contribución de esta entrega consiste en precisar el problema predictivo, revisar modelos pertinentes y establecer cómo se entrenan y evaluarán cuando existan datos utilizables. Se desarrollan cuatro familias principales: Random Forest, redes bayesianas con posible extensión dinámica, redes recurrentes LSTM y redes neuronales de grafos con componente temporal.

Se comparan sus fundamentos, requisitos, aplicaciones, ventajas y limitaciones. La propuesta prioriza una evaluación supervisada de la siguiente acción y de manera complementaria, de trayectorias y receptores. La comparación se realizará con particiones por partido y tiempo, referencias simples y métricas de discriminación, calibración y error espacial. No se reportan modelos entrenados ni mejoras empíricas atribuibles a estas arquitecturas. Se concluye que la recuperación de identidades, reloj y balón constituye una condición previa para evaluar su utilidad.

La selección definitiva dependerá de la evidencia obtenida con partidos reservados y del coste de procesamiento.

Palabras clave: fútbol, predicción de jugadas, aprendizaje supervisado, Random Forest, redes bayesianas, LSTM, redes de grafos.

## **Propósito y alcance de la Entrega**

La entrega originalmente prevista corresponde al análisis inicial de datos. Ante la disponibilidad exclusiva de muestras con problemas de calidad, el asesor propuso incorporar los modelos investigados y explicar su aplicación al objetivo del proyecto. Este documento atiende esa orientación mediante un avance metodológico sustentado en literatura y en el diagnóstico previo de los archivos. Su propósito es dejar preparado un diseño experimental que pueda ejecutarse y auditarse cuando se reciba información completa y suficientemente confiable.

El alcance comprende la formulación de tareas, la definición de variables, el análisis de cuatro modelos y un protocolo de evaluación. Las aplicaciones al fútbol que se plantean en cada apartado son propuestas del equipo. Las referencias fundamentan los métodos y los antecedentes, pero no certifican su desempeño en nuestra muestra. Las cifras del diagnóstico proceden de los archivos de trabajo identificados en el anexo A; no se presentan como una nueva auditoría del histórico ni como resultados de entrenamiento.

La organización del trabajo conserva la orientación de CRISP-ML(Q), que integra el aseguramiento de calidad dentro del proceso de aprendizaje automático. Esta perspectiva permite documentar restricciones y criterios para avanzar entre comprensión de datos, preparación, modelado y evaluación, sin asumir que disponer de un archivo implica contar con un conjunto apto para entrenar (Studer et al., 2021).

## **Situación actual de los datos**

La auditoría inicial registrada en el proyecto examinó un libro de Excel y una muestra en Parquet. El libro contiene 10,000 filas de datos y 44 columnas; el Parquet contiene 793,273 registros. Estos tamaños describen únicamente las muestras inspeccionadas. No permiten establecer cuántos partidos o temporadas estarán disponibles, ni la frecuencia real y calidad del histórico futuro. La incorporación de nuevos archivos deberá acompañarse de un inventario por partido, periodo, fuente y versión.

En Excel, 9,999 celdas del campo de personas tienen exactamente 32,767 caracteres. La inspección previa de ejemplos mostró listas incompletas, lo que constituye evidencia de truncamiento de la exportación. El dato no significa que todas las variables del libro sean inválidas, pero impide recuperar desde esas celdas la totalidad de personas y articulaciones. Convertir el archivo a otro formato no

reconstruye el contenido que dejó de almacenarse. Se requiere la fuente anterior a esa exportación.

En el Parquet se documentaron dorsales repetidos dentro de un mismo instante y 95,289 registros sin dorsal. El reloj match\_time contiene solo cuatro valores y joint\_time presenta retrocesos. Tampoco se conservan identificadores suficientes para vincular inequívocamente partido, periodo, equipo y jugador, ni una identificación explícita del balón. Por tanto, ordenar por un reloj aislado o unir observaciones únicamente por dorsal podría producir trayectorias artificiales.

**Tabla 1**  
***Hallazgos documentados y consecuencias para el modelado***

| Hallazgo                       | Evidencia local                                                | Consecuencia                                                   |
|--------------------------------|----------------------------------------------------------------|----------------------------------------------------------------|
| Listas de personas incompletas | out.xlsx, Sheet1, X2:X10001; 9,999 celdas de 32,767 caracteres | Solicitar el original antes de generar trayectorias colectivas |
| Identificación ambigua         | Parquet; 66,778 grupos tiempo y dorsal con más de una fila     | Recuperar identificador de persona y equipo                    |
| Registros sin dorsal           | Parquet; 95,289 registros, aproximadamente 12.01 %             | Confirmar tipo de objeto; no asumir que corresponden al balón  |
| Reloj insuficiente             | match_time con cuatro valores; joint_time con 11 retrocesos    | Reconstruir tiempo con documentación del proveedor             |
| Balón sin identificar          | Esquema de la muestra Parquet                                  | Posponer tareas de posesión, pase y recepción                  |

Nota. Elaboración a partir del diagnóstico del 14 de septiembre de 2026 conservado en el proyecto. Las ubicaciones y archivos de respaldo se detallan en el anexo A. No se ha vuelto a ejecutar la auditoría para esta entrega.

La muestra permitió una comprobación descriptiva limitada: se recuperó el primer objeto persona íntegro y se comparó persistencia con extrapolación a velocidad constante. En esa trayectoria, el error medio de posición final de velocidad constante fue de 0.306 m, 0.947 m y 2.909 m a horizontes de 0.5, 1 y 2 s, respectivamente.

El cálculo utilizó 117, 115 y 111 ventanas, según el horizonte. Estas ventanas se solapan y provienen de un mismo fragmento; no son evidencia de generalización a otros partidos. El ejercicio demuestra cómo construir una referencia cinemática, pero no valida una predicción de acciones ni un modelo neuronal.

El diagnóstico conduce a una decisión metodológica: los errores estructurales deben resolverse antes de comparar arquitecturas. Una imputación estadística puede estimar un valor ausente bajo ciertos supuestos; no puede certificar identidades perdidas ni recuperar con exactitud una exportación truncada. Hasta contar con datos

apropiados, se pueden preparar esquemas, controles, código de evaluación y ejemplos sintéticos claramente identificados, sin asignarles valor de evidencia futbolística.

### **Definición del problema de predicción**

La expresión siguiente jugada reúne problemas distintos. Predecir una posición futura es una tarea de regresión; predecir un pase o tiro es clasificación; seleccionar un receptor puede formularse como clasificación entre candidatos o como ordenamiento de opciones. Evaluar si una alternativa sería mejor exige además definir utilidad y consecuencias. La separación entre tareas facilita elegir modelos, construir etiquetas y evitar comparar métricas que responden a preguntas diferentes.

El objetivo principal propuesto consiste en estimar la distribución de probabilidad de la siguiente acción del poseedor a partir de información disponible hasta un instante de observación. Las categorías iniciales podrían incluir pase, conducción, tiro y despeje, siempre que el diccionario de eventos permita distinguirlas de forma consistente. La pérdida de posesión se tratará preferentemente como desenlace o transición de estado, porque puede resultar de diferentes acciones y no constituye siempre una elección del jugador.

Se propone comenzar con instantes situados 0.5, 1 y 2 s antes de eventos etiquetados, comprobando que la posesión y el actor estén definidos. Este diseño facilita una primera evaluación de anticipación, pero está condicionado a conocer retrospectivamente que ocurrirá un evento. En una fase posterior, el sistema deberá evaluarse a intervalos regulares durante juego activo, con una clase sin evento dentro del horizonte o con un modelo de tiempo hasta el evento. De ese modo, no se confundirá una prueba centrada en eventos con funcionamiento continuo.

Como objetivos secundarios se consideran la selección de receptor, condicionada a que ocurra un pase y la predicción del desplazamiento de jugadores y balón. Para el receptor se distinguirá entre destinatario intentado y primer contacto efectivo; en pases interceptados no son equivalentes. Si el proveedor solo registra contactos, el objetivo deberá nombrarse según esa información. Dick et al. (2022) ofrecen un antecedente útil al distinguir la disponibilidad de recepción de la elección efectiva de un pase.

La pregunta de investigación es cuánto aportan el historial de movimiento, las dependencias probabilísticas y las interacciones entre jugadores a la anticipación, frente a referencias sencillas. Se plantean tres hipótesis de trabajo: el contexto colectivo podría mejorar las predicciones individuales; la secuencia reciente podría aportar información adicional a una fotografía del estado; y las articulaciones podrían contribuir si su cobertura y precisión son suficientes. Estas hipótesis permanecen abiertas y se contrastarán mediante experimentos que agreguen fuentes de información de forma gradual.

## Fundamentos y preparación común

En aprendizaje supervisado se aprende una relación entre observaciones de entrada y resultados conocidos. En este proyecto, cada ejemplo deberá contener una ventana histórica y una etiqueta futura construida con reglas explícitas. Las etiquetas provendrán de eventos sincronizados o de anotaciones revisadas; una regla automática sin validación puede introducir errores sistemáticos. La evaluación debe reflejar el uso previsto y medir desempeño sobre datos que no hayan intervenido en el ajuste (James et al., 2023).

El conjunto de entrenamiento tendrá una clave de partido, periodo, instante y entidad. El dorsal será un atributo descriptivo. Las coordenadas deberán conservar unidades, dimensiones de cancha y transformaciones aplicadas; el sentido de ataque se normalizará de manera consistente. Velocidades y aceleraciones se calcularán por identidad y segmento continuo, considerando el intervalo real de tiempo y evitando cruzar pausas, sustituciones o pérdidas de seguimiento.

**Tabla 2**  
***Variables propuestas y condiciones para utilizarlas***

| Grupo                 | Ejemplos de variables                                                 | Condición de uso                                  |
|-----------------------|-----------------------------------------------------------------------|---------------------------------------------------|
| Estado individual     | Posición, velocidad, aceleración, cambio de dirección                 | Identidad y tiempo continuo validados             |
| Relaciones espaciales | Distancia a compañeros, rival más cercano y portería; ángulos de pase | Equipos, ejes y dimensiones confirmados           |
| Balón y posesión      | Posición, altura, velocidad, distancia al poseedor                    | Balón identificado y posesión revisada            |
| Contexto              | Periodo, tiempo, marcador, acción previa y fase de juego              | Información disponible al instante de predicción  |
| Historia              | Resúmenes de movimiento y secuencia de eventos recientes              | Ventana que no cruce interrupciones               |
| Articulaciones        | Orientación de hombros y cadera, distancia pie y balón                | Cobertura, precisión y sincronización verificadas |

Nota. Las variables constituyen una propuesta de diseño. Su inclusión definitiva depende del diccionario, la cobertura y los permisos de los datos recibidos. No se presupone disponibilidad de video ni de todas las articulaciones.

Para los modelos tabulares, una ventana podrá resumirse mediante valores actuales, tendencias y variaciones recientes. Para LSTM se conservará el orden temporal y para redes de grafos se representarán explícitamente las entidades y sus relaciones.

La comparación distinguirá el efecto de la arquitectura del efecto de utilizar más información: además del mejor modelo de cada familia, se ejecutarán versiones con entradas comparables.

## **Modelo uno Random Forest**

### **Fundamento y pertinencia**

Random Forest combina árboles de decisión contruidos con aleatoriedad en el entrenamiento y en la selección de variables. En clasificación agrega sus estimaciones para obtener una predicción; en regresión combina valores numéricos. La diversidad entre árboles ayuda a reducir la variabilidad de un árbol individual. El método fue formalizado por Breiman (2001) y constituye una referencia pertinente para relaciones no lineales en variables tabulares.

En el proyecto, su principal utilidad sería establecer un punto de comparación exigente y relativamente accesible. Permitiría comprobar si un conjunto de variables geométricas y temporales resume información suficiente para anticipar acciones. Su uso inicial no implica asumir que será inferior o superior a una red profunda. La elección dependerá de resultados en partidos reservados y de los recursos necesarios para obtenerlos.

### **Aplicación propuesta**

Cada fila representará una situación observada antes de una acción. Las entradas incluirán posición del poseedor, velocidad, distancia del rival más cercano, cantidad de compañeros en zonas relevantes, ángulo hacia portería e historial reciente. El objetivo principal será clasificar el siguiente tipo de acción. En un experimento separado, se podrá estimar una zona de destino o un desplazamiento futuro mediante regresión, manteniendo diferenciadas las métricas.

Un ejemplo de uso sería estimar cómo se distribuyen las probabilidades de pase, conducción y tiro cuando un poseedor avanza bajo presión y cuenta con compañeros en distintas posiciones. El modelo recibiría mediciones, no descripciones subjetivas como juega bien o tiene intención ofensiva. La presión se operacionalizaría con distancias y aproximación de rivales; las definiciones y parámetros se fijarían usando entrenamiento y validación.

La ejecución propuesta comprenderá la generación de variables, el ajuste de un clasificador y la búsqueda acotada de hiperparámetros. Se examinarán profundidad, tamaño mínimo de hojas, número de árboles y variables consideradas en cada división.

Si existe desbalance entre acciones, se probarán ponderaciones de clase dentro del entrenamiento. Las probabilidades se revisarán y si es necesario, se calibrarán con datos de validación independientes del conjunto final de prueba.

### **Ventajas y limitaciones**

Una ventaja operativa es poder comenzar con tablas manejables y observar qué características ayudan a la predicción. Se propone analizar importancia por permutación en partidos de validación, evitando interpretar una importancia alta como relación causal. Cuando varias variables expresen información semejante, su importancia individual podrá resultar ambigua; por ello también se compararán grupos de variables y versiones reducidas.

La principal limitación para este proyecto es que el modelo no representa por sí mismo una secuencia colectiva. Depende de cómo se resuma el pasado y de cómo se codifiquen compañeros y rivales. Se evitarán columnas cuyo significado cambie de un partido a otro, como una posición arbitraria del jugador en la lista de entrada. Tampoco se empleará el error fuera de bolsa como sustituto de una prueba por partidos, pues observaciones cercanas de una misma secuencia pueden ser muy dependientes.

El criterio para conservar Random Forest será su combinación de desempeño, calibración, estabilidad y coste. Si resulta competitivo con modelos más complejos, podrá funcionar como solución principal para acciones o como referencia permanente. Su primer entregable sería una tabla de resultados por clase, una matriz de confusión y un análisis de errores vinculados a situaciones reales.

## **Modelo dos Redes bayesianas**

### **Fundamento y pertinencia**

Una red bayesiana representa una distribución conjunta mediante un grafo dirigido acíclico y distribuciones condicionadas. Los nodos corresponden a variables y las conexiones expresan dependencias del modelo. Esta estructura permite calcular probabilidades a partir de evidencia parcial y formular supuestos de independencia de manera explícita. La formulación gráfica no convierte automáticamente una asociación en una relación causal (Koller & Friedman, 2009).

Su aplicación al proyecto permitiría estudiar un conjunto reducido de variables futbolísticas interpretables. Una estructura inicial podría relacionar zona del campo, presión, disponibilidad de receptores, orientación corporal y tipo de acción. Las conexiones representarían hipótesis estadísticas que deben revisarse con datos y

conocimiento del juego. Se priorizaría un modelo acotado para evitar tablas de probabilidades excesivamente grandes.

### **Aplicación propuesta**

La salida sería una distribución de la siguiente acción condicionada a las variables observadas. Por ejemplo, se examinaría cómo cambia la estimación de pase al disponer de diferentes configuraciones de presión y receptores. Si falta una variable, podría realizarse inferencia marginal bajo el modelo; esto no equivale a recuperar el valor real ausente ni resuelve pérdidas de identidad en el archivo de origen.

Se propone comenzar con una estructura acordada conceptualmente y estimar sus parámetros utilizando los partidos de entrenamiento. Una segunda versión podría explorar estructura aprendida con restricciones temporales y de dominio. Ambas utilizarían las mismas particiones de evaluación. La selección entre variables discretizadas y distribuciones para variables continuas dependerá de tamaño de muestra, estabilidad y capacidad de inferencia.

Si se discretizan distancias o velocidades, los puntos de corte deberán definirse mediante criterios del dominio o a partir del entrenamiento. La categoría presión alta no se fijará por conveniencia posterior al examen de resultados. Se hará un análisis de sensibilidad para comprobar si pequeñas modificaciones de los intervalos cambian de manera importante las predicciones.

### **Extensión temporal y límites**

La extensión dinámica permite conectar variables de instantes sucesivos. Murphy (2002) desarrolla las redes bayesianas dinámicas como una representación de procesos estocásticos y de estados parcialmente observados. En nuestra aplicación podría vincularse el estado reciente de posesión o presión con la acción posterior, sin suponer que una sola imagen describe toda la situación.

La versión dinámica se considerará después de validar la red inicial y el reloj. Se comparará el uso del estado actual con una versión que incorpore historia. El objetivo será comprobar si la estructura temporal mejora la anticipación, no asignar significado psicológico a estados latentes. Los estados inferidos solo podrán interpretarse como categorías tácticas cuando existan criterios externos para sustentarlo.

Las redes bayesianas facilitan comunicar supuestos, pero su estimación puede volverse inestable cuando hay muchas combinaciones y pocos ejemplos. Un histórico grande en filas puede contener pocas situaciones tácticas independientes. El criterio de selección será la calidad probabilística en partidos reservados y la estabilidad de las conclusiones, junto con una complejidad que permita inspeccionar el modelo.

## **Modelo tres Redes recurrentes LSTM**

### **Fundamento y pertinencia**

Las redes Long Short-Term Memory, conocidas como LSTM, fueron propuestas para aprender dependencias en secuencias mediante un estado interno y mecanismos de control de información. Su motivación original aborda dificultades de aprendizaje de dependencias prolongadas en redes recurrentes (Hochreiter & Schmidhuber, 1997). Para nuestro problema, ofrecen una manera de incorporar la evolución del movimiento en lugar de limitarse a variables de un solo instante.

La hipótesis es que una secuencia de aproximación, cambio de dirección o desaceleración podría contener señales relacionadas con la acción posterior. Esta contribución deberá medirse: una mayor capacidad temporal no garantiza una mejor predicción cuando el historial está mal sincronizado o cuando las etiquetas son poco consistentes.

### **Aplicación propuesta**

Se construirán ventanas históricas con posiciones, velocidades, balón y contexto. Como punto de partida experimental se proponen entre dos y cuatro segundos de historia, con evaluación a 0.5, 1 y 2 s. La frecuencia de muestreo se seleccionará después de confirmar la frecuencia original y de medir si una reducción altera señales relevantes. Las ventanas se descartarán o enmascararán cuando existan huecos incompatibles con los criterios de calidad.

El primer modelo LSTM se centrará en el poseedor, el balón y resúmenes del entorno, para mantener acotada la entrada. Posteriormente podría utilizar representaciones por jugador con identidades consistentes. La salida principal será el tipo de acción; una salida secundaria de desplazamiento requerirá un entrenamiento y una evaluación explícitos. Si se combinan tareas, se analizará si una mejora a costa de deteriorar la otra.

Durante el entrenamiento se usarán normalización estimada con el conjunto de entrenamiento, regularización y detención temprana según validación. Se registrarán semillas, longitud de ventana y tamaño del modelo. La información disponible al instante de corte será la única entrada. Una etiqueta de futuro puede utilizarse como objetivo supervisado, pero nunca como característica de la ventana de observación.

### **Evaluación y limitaciones**

La comparación principal será contra los modelos tabulares que utilicen resúmenes del mismo intervalo. Esto permitirá valorar si conservar la secuencia aporta más que sus estadísticas agregadas. Se realizará un experimento con distinta longitud histórica y otro con eliminación de grupos de variables. La decisión de ampliar historia se basará en validación, manteniendo intacto el conjunto final de prueba.

LSTM requiere continuidad temporal y suficientes ejemplos variados. Además, concatenar arbitrariamente a todos los jugadores en una secuencia puede hacer que el modelo dependa del orden de entrada. La arquitectura propuesta evita comenzar con esa representación y reserva las relaciones colectivas explícitas para la siguiente familia. Una predicción promedio de coordenadas tampoco describe necesariamente las diferentes alternativas que un jugador podría ejecutar.

Se conservará este modelo si mejora la anticipación en partidos nuevos y mantiene una latencia compatible con el uso previsto. Los resultados deberán desglosarse por horizonte y tipo de acción. Un buen promedio global no compensará errores sistemáticos en categorías raras o en situaciones de presión que sean relevantes para el proyecto.

## **Modelo cuatro Redes neuronales de grafos temporales**

### **Fundamento y pertinencia**

Las redes neuronales de grafos procesan entidades y relaciones. Los nodos pueden representar jugadores y balón; las aristas, relaciones espaciales o pertenencia a equipos. Mediante intercambio de información, cada representación incorpora características de sus vecinos. Esta formulación permite tratar explícitamente la estructura relacional del problema (Sanchez-Lengeling et al., 2021).

En fútbol, un desplazamiento adquiere significado en relación con compañeros, rivales y balón. La hipótesis del equipo es que un modelo relacional podría mejorar la anticipación en situaciones donde la presión y las opciones de apoyo resultan decisivas. TacticAI demuestra una aplicación de aprendizaje geométrico en tiros de esquina, con tareas de receptor, tiro y ajustes tácticos; su alcance específico no debe extrapolarse a todo el juego abierto (Wang et al., 2024).

### **Aplicación propuesta**

Se construirá un grafo por instante con los participantes presentes y el balón identificado. Los nodos incluirán posición, velocidad, equipo y tipo de entidad. Las relaciones podrán incorporar distancia relativa, ángulo y aproximación. Se comparará un grafo denso con una versión de vecindad restringida, sin asumir de antemano que conectar todas las entidades es necesario o conveniente.

El componente temporal procesará la secuencia de grafos o las representaciones históricas de los nodos. Para una primera implementación se propone combinar una capa de intercambio de información espacial con un módulo recurrente. La clasificación de acción utilizará el estado del poseedor y del contexto; la selección de receptor asignará puntuaciones a los candidatos válidos, conservando su identidad real y enmascarando entidades que no puedan ser destinatarios.

Un experimento específico consistirá en anticipar el receptor antes de que el balón salga del pie del pasador. Se definirán instantes de corte previos al contacto y una etiqueta compatible con el diccionario de eventos. La disponibilidad de un receptor, su elección y el éxito final del pase se tratarán como resultados diferentes. La literatura sobre disponibilidad de pase ayuda a delimitar esta distinción (Dick et al., 2022).

### **Evaluación y limitaciones**

Para verificar que el modelo aprovecha las relaciones, se comparará con una versión sin intercambio entre jugadores y con una versión sin información del balón. También se revisará que reordenar los nodos no cambie injustificadamente la salida correspondiente a la misma persona. Los pesos de atención, cuando existan, se interpretarán como elementos internos de cálculo y no como demostración causal de una decisión.

Esta familia tiene el mayor requisito de integridad colectiva entre los modelos propuestos. Los cambios de identidad, la ausencia del balón o una asignación equivocada de equipo modificarían el grafo. La arquitectura no corrige automáticamente esos problemas. También se deberá justificar el incremento de memoria, preparación e inferencia frente a alternativas tabulares y recurrentes.

Se recomienda incorporarla después de establecer referencias y contar con fragmentos multijugador confiables. Su permanencia dependerá de mejoras en partidos reservados, especialmente en contextos donde las interacciones sean relevantes. No se adopta como ganadora anticipada ni se presupone que las métricas de otras ligas sean transferibles.

### **Comparación y prioridad de implementación**

Los cuatro modelos representan formas diferentes de organizar la información. Random Forest utiliza características tabulares; la red bayesiana explícita dependencias probabilísticas; LSTM conserva la secuencia; y la red de grafos modela interacciones. La comparación no debe reducirse a buscar el mayor porcentaje de acierto: debe considerar información disponible, calidad de probabilidades, complejidad, trazabilidad y tiempo de ejecución.

**Tabla 3**  
***Prioridad experimental y requisitos de los modelos***

| <b>Modelo</b> | <b>Representación</b>    | <b>Aporte por contrastar</b>                                | <b>Prioridad propuesta</b>              |
|---------------|--------------------------|-------------------------------------------------------------|-----------------------------------------|
| Random Forest | Tabla por situación      | Referencia no lineal con variables geométricas e históricas | Primera comparación supervisada         |
| Red bayesiana | Variables y dependencias | Inferencia probabilística con supuestos explícitos          | En paralelo con una estructura reducida |
| LSTM          | Ventana temporal         | Información aportada por el orden del movimiento            | Después de validar continuidad          |
| GNN temporal  | Secuencia de grafos      | Información de compañeros, rivales y balón                  | Tras recuperar tracking colectivo       |

Nota. La prioridad expresa una propuesta operativa, no una clasificación de desempeño observado. Todos los modelos deben evaluarse con el mismo objetivo y particiones cuando se comparen directamente.

Se incorporará una regresión logística multinomial como referencia supervisada simple y una predicción de clase mayoritaria para contextualizar el desbalance. En trayectorias se conservarán persistencia y velocidad constante. Estas referencias permitirán distinguir si el aumento de complejidad produce una mejora verificable. La elección final podrá favorecer un modelo más sencillo si el beneficio del más complejo es pequeño o inestable.

## **Protocolo de entrenamiento y evaluación**

### **Separación de los datos y prevención de fuga**

La división se realizará antes de generar ventanas. Se reservarán partidos completos para prueba y se respetará la cronología cuando el objetivo sea anticipar encuentros futuros. La proporción dependerá del número real de partidos; no se fija una partición por temporadas que aún no están confirmadas. Durante desarrollo se utilizará validación agrupada por partido y el conjunto final se evaluará después de cerrar decisiones de modelado.

Las transformaciones, imputaciones, normalización, selección de variables y calibración se ajustarán sin consultar la prueba. Se inspeccionará si el proveedor aplica suavizado o correcciones que utilicen frames posteriores: una coordenada retrospectivamente corregida puede contener información que no habría estado disponible en vivo. El mismo control se aplicará a posesión, etiquetas derivadas y marcadores temporales.

También se evitará que versiones de un mismo partido o secuencias duplicadas aparezcan en conjuntos distintos. Si se utilizan identidades de jugador o equipo como entradas, se reportará su efecto y se realizará, cuando la cobertura lo permita, una prueba con entidades no vistas. El propósito es diferenciar aprendizaje del contexto de memorización de patrones particulares.

### **Métricas y criterios de comparación**

Para acciones se reportarán macro-F1, precisión y exhaustividad por clase, matriz de confusión y soporte de cada categoría. La exactitud global se utilizará como información complementaria. Para probabilidades se calcularán log-loss y Brier multiclase, junto con diagramas de calibración. La calibración permitirá contrastar si eventos asignados a un intervalo de probabilidad ocurren con una frecuencia compatible.

Para receptor se utilizará acierto top-1 y top-3 sobre candidatos válidos, además de log-loss cuando exista una distribución normalizada. Para trayectorias se calcularán ADE, promedio de distancias a lo largo del horizonte y FDE, distancia al final. Se informarán unidades, horizontes, tamaño de muestra y percentiles de error. Si se generan varias alternativas, se fijará su número y no se reportará únicamente el mejor caso entre muchas muestras.

La incertidumbre de las diferencias entre modelos se estimará respetando la dependencia por partido, por ejemplo mediante remuestreo de partidos. Se registrarán latencia mediana, percentil 95, memoria y hardware de medición. No se establecerá como meta un porcentaje tomado de otra publicación: primero se obtendrán referencias locales y después se acordará qué mejora resulta útil para el uso previsto.

### **Experimentos para medir el aporte de cada fuente**

Se propone una secuencia de experimentos con posiciones y velocidades; adición del balón; incorporación de eventos y contexto; y finalmente, articulaciones si superan los controles de calidad. Cuando haya video sincronizado, se evaluará en una extensión separada. La ausencia de esa modalidad no impide estudiar modelos con tracking; tampoco se supondrá que los datos visuales son necesarios si las mediciones estructuradas ya responden al objetivo.

Cada ejecución conservará versión de datos, reglas de etiquetas, particiones, parámetros, semilla y métricas. Los errores se revisarán mediante fragmentos de juego y tablas de evidencia. Se examinarán por separado confusiones debidas a etiquetas, pérdidas de seguimiento y limitaciones del modelo. Esta distinción permitirá decidir si conviene mejorar la preparación o cambiar la arquitectura.

**Relación con aprendizaje por refuerzo y simulación**

El aprendizaje por refuerzo estudia políticas que buscan maximizar una recompensa acumulada mediante decisiones secuenciales. Su formulación requiere estados, acciones, transiciones y recompensas; constituye una rama diferente de la clasificación supervisada de la próxima acción observada (Sutton & Barto, 2018). En nuestro proyecto se mantiene como extensión para evaluar decisiones dentro de un entorno definido.

El aprendizaje por refuerzo inverso busca inferir una recompensa compatible con comportamientos observados. Diferentes recompensas pueden explicar una conducta semejante, por lo que no equivale a recuperar de manera única la intención mental de un jugador (Ng & Russell, 2000). Su incorporación requeriría una pregunta específica, representación de acciones y supuestos sobre dinámica y conducta experta.

La existencia de investigación con refuerzo offline en fútbol muestra una ruta basada en históricos, pero no elimina la necesidad de evaluar cobertura y extrapolación. Rahimian et al. (2024) integran eventos y tracking para tareas de acciones y resultados; sus resultados pertenecen a su configuración experimental. Esta entrega no propone reproducir sus cifras ni entrenar RL con los ejemplos actuales.

La predicción supervisada será el primer eje experimental. La simulación posterior deberá permitir que las acciones modifiquen el estado y tendrá métricas propias de coherencia, reglas y utilidad. La reproducción de una secuencia histórica seguirá siendo una herramienta de inspección. Mantener esas funciones separadas evitará interpretar una animación plausible como prueba de una política táctica eficaz.

**Plan de trabajo condicionado a la recepción de datos**

**Tabla 4**  
***Etapas y evidencias necesarias para avanzar***

| <b>Etapas</b> | <b>Actividad</b>                                                          | <b>Evidencia de cierre</b>                         |
|---------------|---------------------------------------------------------------------------|----------------------------------------------------|
| Recuperación  | Recibir originales y diccionario;<br>confirmar cobertura y uso autorizado | Inventario y campos identificados                  |
| Auditoría     | Revisar identidades, reloj,<br>coordenadas, balón y continuidad           | Informe reproducible y exclusiones<br>justificadas |
| Etiquetado    | Sincronizar eventos y revisar ejemplos                                    | Reglas de etiqueta y muestra<br>validada           |

| <b>Etapas</b> | <b>Actividad</b>                                      | <b>Evidencia de cierre</b>                |
|---------------|-------------------------------------------------------|-------------------------------------------|
| Referencias   | Evaluar reglas, logística y Random Forest             | Métricas por partido y horizonte          |
| Comparación   | Ajustar red bayesiana, LSTM y GNN cuando sean viables | Resultados con particiones compartidas    |
| Selección     | Contrastar utilidad, estabilidad y coste              | Modelo recomendado y límites documentados |

Nota. No se asignan fechas de entrenamiento hasta conocer la recepción y calidad de los datos. El avance actual cubre el diagnóstico documentado, la revisión de modelos y el diseño experimental.

Mientras se reciben los originales se pueden completar el diccionario propuesto, los validadores de esquema y las funciones de construcción de ventanas. Las pruebas con datos artificiales solo verificarán el funcionamiento del procesamiento. La autorización de acceso, almacenamiento y difusión deberá documentarse; no se considera confirmada por disponer de un ejemplo o por recibir archivos parcialmente.

## Referencias

- Breiman, L. (2001). Random forests. *Machine Learning*, 45, 5–32. <https://doi.org/10.1023/A:1010933404324>
- Dick, U., Link, D., & Brefeld, U. (2022). Who can receive the pass? A computational model for quantifying availability in soccer. *Data Mining and Knowledge Discovery*, 36, 987–1014. <https://doi.org/10.1007/s10618-022-00827-2>
- Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). *An introduction to statistical learning: With applications in Python*. Springer. <https://doi.org/10.1007/978-3-031-38747-0>
- Koller, D., & Friedman, N. (2009). *Probabilistic graphical models: Principles and techniques*. MIT Press. <https://mitpress.mit.edu/9780262013192/probabilistic-graphical-models/>
- Murphy, K. P. (2002). *Dynamic Bayesian networks: Representation, inference and learning* [Tesis doctoral, University of California, Berkeley]. <https://www2.eecs.berkeley.edu/Pubs/TechRpts/2002/8174.html>
- Ng, A. Y., & Russell, S. (2000). Algorithms for inverse reinforcement learning. En P. Langley (Ed.), *Proceedings of the Seventeenth International Conference on Machine Learning* (pp. 663–670). Morgan Kaufmann. <https://ai.stanford.edu/~ang/papers/icml00-irl.pdf>
- Rahimian, P., Mihályi, B. M., & Toka, L. (2024). In-game soccer outcome prediction with offline reinforcement learning. *Machine Learning*, 113, 7393–7419. <https://doi.org/10.1007/s10994-024-06611-1>
- Sanchez-Lengeling, B., Reif, E., Pearce, A., & Wiltchko, A. B. (2021). A gentle introduction to graph neural networks. *Distill*. <https://doi.org/10.23915/distill.00033>
- Studer, S., Bui, T. B., Drescher, C., Hanuschkin, A., Winkler, L., Peters, S., & Müller, K.-R. (2021). Towards CRISP-ML(Q): A machine learning process model with quality assurance methodology. *Machine Learning and Knowledge Extraction*, 3(2), 392–413. <https://doi.org/10.3390/make3020020>
- Sutton, R. S., & Barto, A. G. (2018). *Reinforcement learning: An introduction* (2.<sup>a</sup> ed.). MIT Press. <http://incompleteideas.net/book/the-book-2nd.html>
- Wang, Z., Veličković, P., Hennes, D., Tomašev, N., Prince, L., Kaisers, M., Bachrach, Y., Elie, R., Wenliang, L. K., Piccinini, F., Spearman, W., Graham, I., Connor, J., Yang, Y., Recasens, A., Khan, M., Beauguerlange, N., Sprechmann, P., Moreno, P., ... Tuyls, K. (2024). TacticAI: An AI assistant for football tactics. *Nature Communications*, 15, Artículo 1906. <https://doi.org/10.1038/s41467-024-45965-x>

## **Anexo A Trazabilidad del diagnóstico previo**

Los siguientes materiales internos permiten localizar los datos y cálculos citados en el diagnóstico. Se identifican como evidencia del proyecto y no como publicaciones académicas. La fecha del informe base es el 14 de septiembre de 2026; esta entrega retoma sus resultados sin ejecutar nuevamente los análisis.

Informe principal: analisis\_proyecto/Panorama\_y\_plan\_del\_proyecto.md. Los apartados Qué muestran los archivos y Primera prueba descriptiva de anticipación contienen el alcance, las comprobaciones y los límites de la exploración.

Resultados de auditoría:

analisis\_proyecto/auditoria.json

analisis\_proyecto/resumen\_numerico.json

analisis\_proyecto/perfil\_datos.txt.

Respaldan la estructura, los problemas de identidad y las características temporales de las muestras.

Prueba descriptiva:

analisis\_proyecto/prueba\_prediccion.json

analisis\_proyecto/prueba\_prediccion.py.

Contienen la evaluación de persistencia y velocidad constante del primer objeto persona recuperable. No equivalen a entrenamiento de ninguno de los cuatro modelos revisados.

Cuaderno de trabajo:

analisis\_proyecto/01\_auditoria\_tracking.ipynb.

Conserva el procedimiento exploratorio registrado. Su reproducción futura deberá comprobar rutas, versiones y correspondencia con los archivos originales.

Ubicaciones en Excel:

Sheet1, X2:X10001 para las listas de personas; AF2:AF10001 y AR2:AR10001 para secuencias de frame; AM2:AM10001 para NETCO\_matchTime; AQ2:AQ10001 para NETCO\_time; AG2:AI2 para unidades declaradas.

En la muestra Parquet, los campos de negocio auditados son match\_time, joint\_time, jerseyNumber y pos.

## **Anexo B Lecturas prioritarias para la implementación**

Para preparar las primeras tablas y referencias se recomienda James et al. (2023), capítulos de aprendizaje estadístico, clasificación, validación y métodos basados en árboles, seguido de Breiman (2001). El producto de esta lectura será una definición de ejemplo supervisado y un clasificador tabular reproducible.

Para la rama probabilística se recomienda consultar Koller y Friedman (2009) sobre representación e inferencia en redes bayesianas y Murphy (2002) para la extensión temporal. El producto será un diagrama de variables, supuestos de dependencia y consultas predictivas, sujeto a validación con datos.

Para las arquitecturas temporales y colectivas se recomienda Hochreiter y Schmidhuber (1997), Sanchez-Lengeling et al. (2021) y Dick et al. (2022). El producto será la especificación de ventanas, nodos, relaciones y etiquetas. Wang et al. (2024) aporta un ejemplo de aplicación en un escenario acotado del fútbol.

Las lecturas de Sutton y Barto (2018), Ng y Russell (2000) y Rahimian et al. (2024) se reservan para delimitar la posterior comparación entre predicción de conducta, aprendizaje de políticas e inferencia de recompensas. Su lectura no modifica la prioridad actual de contar con datos íntegros y referencias supervisadas.