

Tecnológico de Monterrey

Soccer Play Prediction

Avance 2. Ingeniería de características

Alumnos:

José Antonio Fernández Pérez	A01795991
Juan José Ponce	A01659811
Hiram García Austria	A00378771

Índice

Objetivo, alcance y evidencia 2
Alcance y criterios de preparación 3
Datos disponibles y trazabilidad 4
Lectura acotada y controles de calidad 7
Construcción de características y justificación futbolística 10
Codificación y separación temporal para prevenir fugas de información 12
Transformación y escalamiento 15
Selección por filtrado y extracción de características 19
Preparación de una representación en grafos para GNN 24
Verificaciones y resultados reproducibles 28
Conclusiones de la preparación de datos en CRISP ML Q 32
Anexo A Código y salidas de ejecución 35
Código 1 Configuración y localización de datos 35
Código 2 Trazabilidad y alineaciones 36
Código 3 Lectura del balón y controles de calidad 37
Código 4 Construcción causal de características 39
Código 5 Codificación y separación temporal 41
Código 6 Transformación y escalamiento 42
Código 7 Filtrado y extracción por PCA 43
Código 8 Constructor de grafos y adaptación al seguimiento 44
Código 9 Verificación y exportación de resultados 47
Anexo B Trazabilidad y controles pendientes 49
Fuentes procesadas 49
Archivos generados 49
Controles pendientes y efecto sobre la preparación 50
Resultado que puede afirmarse 50
Anexo C Ejecución y entrega 51
Datos y entorno 51
Procedimiento de ejecución secuencial 51
Comprobación local realizada 52

Índice de tablas

Tabla 1. Registro de titulares y jugadores en banca por equipo 5
Tabla 2. Tamaño de los archivos fuente utilizados 6
Tabla 3. Resultados de la lectura y procesamiento de datos 9
Tabla 4. Estado de los campos play y bounds 9
Tabla 5. Características cinemáticas construidas para el balón 11
Tabla 6. Distribución temporal de los bloques de datos 14
Tabla 7. Comparación de asimetría antes y después de log1p 17
Tabla 8. Comprobaciones de estandarización en entrenamiento 18
Tabla 9. Variables excluidas por correlación perfecta 20
Tabla 10. Reducción de columnas durante el filtrado 21
Tabla 11. Resultados de la extracción mediante PCA 21
Tabla 12. Error de reconstrucción por bloque temporal 22
Tabla 13. Tamaño de las representaciones de datos 23
Tabla 14. Atributos de nodo para la construcción de grafos 25
Tabla 15. Atributos de relación para la construcción de grafos 26
Tabla 16. Archivos generados y finalidad 30
Tabla 17. Resumen de resultados reproducibles 31
Tabla 18. Correspondencia entre bloques de código y secciones 35
Tabla 19. Archivos fuente, tamaño y uso 49
Tabla 20. Contenido de los archivos de resultados 49
Tabla 21. Controles pendientes y acciones requeridas 50

Objetivo, alcance y evidencia

Desarrollar un proceso reproducible de ingeniería de características que transforme los datos de seguimiento del balón y de los jugadores en variables cinemáticas, espaciales y contextuales útiles para representar episodios futbolísticos y apoyar su posterior predicción de corto plazo. Para ello, se aplicarán técnicas de construcción, codificación, escalamiento, selección y extracción de características, justificando cada decisión según la naturaleza de los datos y su utilidad para el aprendizaje automático, dentro de la fase de preparación de datos de CRISP-ML(Q) (Visengeriyeva et al., 2023).

El proceso contempla la organización de las observaciones en grafos por instante y secuencias de grafos por episodio, mediante atributos de nodos y relaciones entre entidades que permitan preparar entradas para una futura red neuronal de grafos (Gilmer et al., 2017). Asimismo, se evaluará el análisis de componentes principales como alternativa para reducir la dimensionalidad de los atributos numéricos, considerando la varianza conservada y el error de reconstrucción (Jolliffe & Cadima, 2016).

La preparación incorporará controles de identidad, continuidad temporal, duplicados y valores faltantes. Las características predictivas utilizarán únicamente información disponible hasta el instante observado, y los parámetros estadísticos se ajustarán exclusivamente con los datos de entrenamiento para prevenir fugas de información (scikit-learn developers, s. f.). La demostración inicial se realizará sobre una muestra real del balón de Genoa–Napoli y se ampliará a la representación de interacciones cuando se disponga del seguimiento de jugadores.

Alcance y criterios de preparación

Para desarrollar el objetivo planteado, se aplican operaciones de construcción, codificación, escalamiento, selección por filtrado y extracción mediante análisis de componentes principales sobre una muestra real del seguimiento del balón del partido Genoa–Napoli del 22 de agosto de 2026. La demostración comprende los primeros tres archivos del balón, correspondientes aproximadamente a los tres minutos iniciales del encuentro y utiliza las alineaciones para relacionar los identificadores con los equipos y jugadores.

Esta muestra permite comprobar el procedimiento de ingeniería de características, pero no representa la totalidad del partido ni la diversidad de situaciones presentes en otros encuentros. Asimismo, se incluye una función para construir grafos a partir del seguimiento de jugadores; su ejecución y validación quedan condicionadas a disponer del archivo correspondiente. Las posiciones tácticas declaradas en las alineaciones se mantienen separadas de las posiciones observadas durante el juego.

El procedimiento se sitúa en la fase de preparación de datos de CRISP-ML(Q), que contempla selección, limpieza, ingeniería de características y estandarización, acompañadas de controles de calidad y documentación reproducible (Visengeriyeva et al., 2023). Por ello, se registran las fuentes utilizadas, las transformaciones aplicadas, sus parámetros y las limitaciones que deben resolverse antes del entrenamiento.

Unidad de análisis y controles de calidad

La unidad de análisis de la demostración es una observación del balón en un instante, con su posición, tiempo y contexto disponible. Para la representación posterior mediante una red neuronal de grafos, se propone organizar las entidades y sus relaciones en un grafo por instante y agrupar estos grafos en secuencias temporales para representar episodios futbolísticos.

Las derivadas y las características históricas se calculan dentro de segmentos temporalmente continuos. Los cambios de periodo y las interrupciones relevantes en la secuencia delimitan segmentos, evitando calcular movimientos a través de observaciones que no sean consecutivas.

La preparación se evalúa mediante los siguientes controles:

- Orden temporal creciente dentro de cada segmento.
- Identificación y tratamiento documentado de duplicados o colisiones en las claves temporales.
- Construcción de características utilizando únicamente información disponible hasta el instante observado.
- Ajuste de los parámetros estadísticos exclusivamente con el bloque de entrenamiento.

- Verificación de valores numéricos finitos después del tratamiento de faltantes.
- Registro de las variables conservadas, la dimensionalidad obtenida y el error de reconstrucción de PCA.

Estos controles permiten verificar la consistencia del procesamiento. La utilidad predictiva de las características deberá evaluarse posteriormente mediante modelos y datos de evaluación independientes. Separar el ajuste de las transformaciones de su aplicación a evaluación permite reducir el riesgo de fuga de información (scikit-learn developers, s. f.-a).

Entorno de ejecución

El procedimiento se ejecutó localmente con Python 3.12.14, NumPy 2.3.5 y pandas 3.0.1. Se utilizaron archivos previamente descargados, por lo que esta ejecución no requirió conexión a AWS ni acceso a credenciales.

Implementación: anexo A, código 1.

Datos disponibles y trazabilidad

La preparación utiliza dos archivos del mismo partido: matchLineups.json, que contiene información de equipos y jugadores y scrubbed_ball_NOT_PARSED.zip, que contiene las muestras de seguimiento del balón. La relación entre ambos permite interpretar los identificadores de equipo registrados en las observaciones y preparar atributos contextuales para el análisis.

El procedimiento de conversión disponible contempla la extracción de posiciones corporales, la vinculación con las alineaciones y el cálculo de variables como velocidad, orientación, dirección de ataque y distancia al balón. Para incorporar estas variables como entradas de una predicción de corto plazo, es necesario comprobar que su cálculo respete la disponibilidad temporal de la información.

Criterios para incorporar el seguimiento de jugadores

La revisión del procesamiento identifica cinco aspectos que deben atenderse antes de utilizar las características de jugadores en un modelo predictivo:

1. **Cálculo causal de la cinemática:** el suavizado centrado y las diferencias centrales utilizan observaciones posteriores al instante analizado. Para producir entradas disponibles en ese instante, se emplearán ventanas históricas y diferencias hacia atrás. Esta distinción evita utilizar información futura durante la preparación de las entradas del modelo (scikit-learn developers, s. f.-a).

2. **Separación entre movimiento y orientación corporal:** la dirección del desplazamiento y la orientación de la pelvis representan información diferente. Se conservarán como variables separadas, acompañadas de indicadores de disponibilidad o validez. Cuando la rapidez sea muy baja, la dirección del desplazamiento se considerará poco fiable.

3. **Interpretación del portador del balón:** la identificación del jugador más cercano al balón dentro de un radio de 1.5 metros se tratará como una estimación por proximidad. Para interpretarla como control individual será necesario comprobar, entre otros factores, la altura del balón y la continuidad temporal de la relación jugador–balón.

4. **Determinación de la dirección de ataque:** la dirección utilizada como característica deberá obtenerse de información disponible antes de la predicción o de una calibración histórica. Se evitará inferirla utilizando observaciones posteriores del mismo periodo.

5. **Calibración de la orientación de caderas:** los parámetros utilizados para resolver la orientación se estimarán con información previa o con el conjunto de entrenamiento y se conservarán al procesar los datos de evaluación.

Estos criterios orientan la ampliación del procedimiento al seguimiento de jugadores. Su validación con datos reales permanece pendiente; la demostración ejecutada en este avance corresponde al balón.

Los metadatos de Juventus–Milan se mantienen separados de la muestra de Genoa–Napoli, ya que describen otro encuentro. Su estructura puede servir como referencia para la integración posterior, pero no constituye evidencia de posiciones o resultados del partido analizado.

Resultados de la lectura de alineaciones

La lectura de matchLineups.json identificó los equipos Genoa y Napoli y permitió organizar sus jugadores según la condición registrada en la alineación.

Tabla 1. Registro de titulares y jugadores en banca por equipo

Equipo	Titulares registrados	Jugadores registrados en banca
Genoa	11	13
Napoli	11	13

Fuente: Elaboración propia.

Los jugadores registrados en banca no se consideran automáticamente participantes en cada instante del encuentro. Para determinar quiénes están efectivamente en cancha será necesario contrastar las sustituciones y la presencia de cada identidad en el seguimiento.

Se encontraron 21 registros de jugadores con el campo events no vacío. Este resultado indica la presencia de contenido en dichos campos, pero no establece el número ni el tipo de eventos: será necesario revisar su estructura antes de utilizarlo como información del partido o como etiqueta de aprendizaje.

Los campos pitchSizeX y pitchSizeY presentan valores nulos. Por tanto, las dimensiones físicas de la cancha no quedan confirmadas mediante este archivo y cualquier transformación que dependa de ellas deberá indicar el supuesto utilizado.

Identificación reproducible de las fuentes

Para documentar los archivos procesados se registraron su tamaño en bytes y su huella SHA-256. Estas huellas permiten comprobar si una ejecución posterior utiliza exactamente los mismos archivos; no certifican por sí solas su calidad o integridad semántica.

Tabla 2. Tamaño de los archivos fuente utilizados

Archivo	Tamaño en bytes
matchLineups.json	49,178
2026-08-22_GENOA-NAPOLI_scrubbed_ball_NOT_PARSED.zip	109,396,388

Fuente: Elaboración propia.

Las huellas SHA-256 completas se conservan en la salida del código 2 y en el archivo de parámetros y resultados, como parte de la trazabilidad del procesamiento.

Implementación y salida completa: anexo A, código 2.

Lectura acotada y controles de calidad

La lectura de los datos se realiza de manera acotada para comprobar el procedimiento de preparación antes de ampliarlo al partido completo. El archivo comprimido del balón contiene 97 miembros reconocidos por su nombre; en esta demostración se procesan únicamente los tres primeros, ordenados numéricamente por periodo y minuto.

Cada miembro seleccionado se carga y procesa individualmente. De esta manera, se evita descomprimir y cargar simultáneamente todo el contenido del ZIP, aunque las observaciones de la muestra seleccionada sí se acumulan en memoria para construir la tabla de trabajo. El orden numérico permite mantener la secuencia temporal, evitando que un ordenamiento alfabético coloque, por ejemplo, el minuto 10 antes del minuto 2.

Se conservan todas las observaciones de los archivos seleccionados, sin reducir deliberadamente la frecuencia de muestreo. Esta decisión mantiene el detalle temporal disponible para calcular movimientos y cambios rápidos del balón; no garantiza, por sí sola, que puedan identificarse contactos o acciones futbolísticas.

Reconstrucción temporal y segmentación

El tiempo de cada observación se reconstruye mediante la siguiente expresión:

$$t = (m - 1) \times 60 + t_local$$

En esta expresión, *m* representa el índice de minuto obtenido del nombre del archivo y *t_local* corresponde al tiempo registrado dentro de ese miembro. El resultado *t* expresa el tiempo reconstruido en segundos.

Esta convención se utiliza para ordenar y relacionar las observaciones de la muestra. Su aplicación entre periodos debe comprobarse posteriormente con el partido completo y con la documentación del proveedor.

Para delimitar segmentos, se identifica el inicio de la secuencia, un cambio de periodo, un intervalo temporal no positivo o una separación entre observaciones superior a 0.05 segundos. Este último valor es un umbral operacional equivalente a 2.5 intervalos nominales de muestreo a 50 Hz. Se utiliza para evitar que las características derivadas interpreten una discontinuidad como movimiento continuo y deberá revisarse al incorporar más datos.

Dentro de cada segmento se verifica que los tiempos sean estrictamente crecientes. Las derivadas y las características históricas se calcularán respetando estos límites, de forma que no atraviesen cambios de periodo ni interrupciones relevantes.

Auditoría de las claves temporales

Se construye una clave formada por el periodo y el índice de frame:

Clave temporal = (periodo, redondear(t × 50))

El índice permite representar el tiempo sobre una cuadrícula nominal de 50 observaciones por segundo. Sin embargo, pequeñas variaciones en las marcas temporales pueden ocasionar que dos observaciones distintas se asignen al mismo frame. Por ello, se revisa tanto la repetición de la clave como la concordancia del contenido asociado.

Cuando las observaciones de una misma clave presentan diferencias en posición o contexto, se exportan a un archivo de cuarentena y se excluyen de la tabla utilizada en esta demostración. Este tratamiento evita seleccionar arbitrariamente una versión y conserva las observaciones para su revisión. La exclusión afecta únicamente a la tabla de trabajo; los archivos originales permanecen intactos.

La cuarentena constituye una medida provisional de calidad. La asignación definitiva de frames y la posible necesidad de conservar ambas observaciones deberán validarse con el proveedor. Este control responde al principio de documentar y mitigar los riesgos de calidad durante la preparación de datos de CRISP-ML(Q) (Visengeriyeva et al., 2023).

Tratamiento de valores y estados

Las coordenadas extremas y las velocidades elevadas se conservan para su revisión, en lugar de eliminarlas o truncarlas automáticamente. Su magnitud puede responder a movimiento real, diferencias de cálculo o problemas de captura; establecer límites de exclusión requiere evidencia adicional.

También se mantienen separadas la velocidad registrada por el proveedor y la velocidad planar que se calculará posteriormente a partir de las coordenadas. Su equivalencia no se presupone, ya que pueden diferir en componentes consideradas, suavizado y procedimiento de estimación.

Los estados desconocidos se conservarán explícitamente durante la codificación. En particular, los campos play y bounds se tratarán como variables distintas y se comprobará su significado antes de utilizarlos para definir periodos de juego activo o balón dentro del terreno.

Estos controles constituyen una revisión de calidad de la muestra utilizada para ingeniería de características. No sustituyen un análisis exploratorio del conjunto completo ni permiten afirmar que todos los partidos presentan las mismas condiciones.

Resultados de la lectura y depuración

La ejecución reconoció 97 miembros en el ZIP y leyó 9,001 observaciones de los tres archivos seleccionados. Se identificó una clave temporal repetida que agrupaba dos observaciones con contenido diferente. Ambas se conservaron en cuarentena, por lo que la tabla de trabajo quedó integrada por 8,999 observaciones.

Tabla 3. Resultados de la lectura y procesamiento de datos

Indicador	Resultado
Miembros reconocidos en el ZIP	97
Miembros procesados	3
Observaciones leídas	9,001
Claves temporales con contenido diferente	1
Observaciones enviadas a cuarentena	2
Observaciones conservadas	8,999
Segmentos identificados	2
Mediana del intervalo temporal dentro de segmentos	0.019999 s
Tiempo inicial reconstruido	0.000057 s
Tiempo final reconstruido	179.985746 s

Fuente: Elaboración propia.

La mediana del intervalo temporal es cercana a 0.02 segundos, lo que resulta consistente con una frecuencia nominal de 50 Hz en la muestra. Esta comprobación no demuestra que todos los intervalos sean regulares ni confirma la continuidad del partido completo.

En las observaciones conservadas no se detectaron valores faltantes en las coordenadas x, y y z. Este resultado corresponde exclusivamente a esos campos y a la muestra procesada; no implica ausencia de errores de posición ni garantiza que otras variables estén completas.

La distribución de los estados registrados fue la siguiente:

Tabla 4. Estado de los campos play y bounds

Campo del proveedor	Estado	Observaciones
play	In	6,547
play	Out	2,452
bounds	In	8,942
bounds	Out	57

Fuente: Elaboración propia.

Las distribuciones diferentes muestran que ambos campos no deben utilizarse indistintamente. Antes de calcular métricas de juego activo o permanencia del balón dentro del terreno, se validará su interpretación con el proveedor.

La salida completa incluye una vista de las primeras observaciones, con tiempo, coordenadas y velocidad registrada. En conjunto, estos resultados proporcionan una tabla ordenada y auditada sobre la cual pueden construirse las características cinemáticas y contextuales de la siguiente sección.

Implementación y salida completa: anexo A, código 3. Las dos observaciones excluidas se conservan en duplicados_en_cuarentena.csv.

Construcción de características y justificación futbolística

A partir de la tabla ordenada y auditada, se construyen características para describir el movimiento del balón, su ubicación y el contexto registrado por el proveedor. Estas variables buscan transformar las observaciones crudas en una representación útil para el análisis de episodios y la preparación de entradas para una posterior predicción de corto plazo.

La selección inicial responde al significado de cada variable dentro del juego y a su disponibilidad temporal. Las características cinemáticas e históricas utilizan únicamente la observación actual y observaciones anteriores del mismo segmento. Este criterio evita incorporar información futura en las entradas del modelo, en concordancia con las recomendaciones para prevenir fugas de información durante el procesamiento de datos (scikit-learn developers, s. f.-a).

Las características se consideran candidatas. Su incorporación definitiva dependerá de los controles de calidad, la selección de variables y la evaluación posterior de su utilidad predictiva. Los umbrales utilizados en esta demostración son decisiones operacionales del equipo y deberán revisarse con más datos.

Características de movimiento

Para cada eje, la velocidad se estima mediante una diferencia hacia atrás:

$v_x(t) = [x(t) - x(t_anterior)] / \Delta t$

Se aplica la misma expresión a las coordenadas y y z, utilizando el intervalo real entre observaciones. El cálculo se reinicia al comenzar un segmento.

Tabla 5. Características cinemáticas construidas para el balón

Característica	Cálculo	Información que aporta
vx, vy, vz	Cambio de cada coordenada dividido entre el intervalo temporal real	Componentes horizontal y vertical del movimiento del balón.
speed_planar	$\sqrt{(vx^2 + vy^2)}$	Rapidez horizontal, calculada a partir de posiciones. Se mantiene separada de la velocidad registrada por el proveedor.
accel_planar	Cambio de speed_planar dividido entre Δt	Tasa de cambio de la rapidez horizontal. Puede identificar aumentos o disminuciones de intensidad, pero es sensible al ruido.
heading_sin	vy / speed_planar, cuando la rapidez supera 0.1 m/s	Componente de la dirección horizontal del movimiento.
heading_cos	vx / speed_planar, cuando la rapidez supera 0.1 m/s	Componente complementaria de la dirección horizontal.
heading_valid	1 si la rapidez calculada supera 0.1 m/s; 0 en otro caso	Indica si la dirección puede calcularse bajo el criterio operacional adoptado.
disp_0p2	Distancia horizontal entre la posición actual y la situada diez observaciones antes, dentro del mismo segmento	Desplazamiento reciente en un intervalo cercano a 0.2 segundos.

Fuente: Elaboración propia.

La representación de la dirección mediante seno y coseno evita la discontinuidad numérica que aparece cuando un ángulo pasa de π a −π, aunque ambas orientaciones sean cercanas. El umbral de 0.1 m/s reduce la interpretación de una dirección cuando el desplazamiento es muy pequeño; no constituye un umbral físico validado de

Codificación y separación temporal para prevenir fugas de información

Después de construir las características, se preparan las variables categóricas y se divide temporalmente la muestra. Estas operaciones permiten definir una representación numérica consistente y establecer qué observaciones podrán utilizarse para ajustar las transformaciones estadísticas posteriores.

La codificación se realiza sobre los roles y la condición de equipo local o visitante registrados en las alineaciones. La separación temporal se aplica a las observaciones del balón. Ambos procedimientos preparan componentes del conjunto de datos, pero la codificación de las alineaciones no implica que ya se hayan incorporado trayectorias de jugadores.

Codificación de variables categóricas

Los roles se representan mediante codificación one-hot, que asigna una columna indicadora a cada categoría. Se consideran las categorías portero, defensor, mediocampista, delantero y rol desconocido. La condición de equipo local o visitante se representa mediante dos columnas adicionales.

Esta decisión evita asignar un orden numérico artificial a categorías que no expresan una jerarquía. Por ejemplo, codificar defensor como 2 y delantero como 4 podría introducir una relación de magnitud que no corresponde al significado de los roles. La codificación one-hot proporciona una representación mediante indicadores, apropiada para variables nominales (scikit-learn developers, s. f.-c).

Los roles ausentes o no reconocidos se asignan a la categoría desconocida, conservando un esquema de columnas definido. En la implementación actual, la condición local o visitante se obtiene de la estructura de las alineaciones y utiliza las categorías home y away; no dispone de una columna adicional de lado desconocido.

Los identificadores de jugador y equipo se mantienen como claves para relacionar registros. Los dorsales también se conservan como atributos de identificación y no se incorporan como una escala numérica de habilidad. La variable starter indica la condición registrada en la alineación, pero no determina por sí sola si un jugador está presente en un instante posterior del encuentro.

La presencia efectiva en cancha deberá comprobarse con el seguimiento y, cuando corresponda, con los registros de sustitución.

Separación cronológica de la muestra

La muestra del balón se divide utilizando dos puntos de corte situados en el 60 % y el 80 % de su intervalo temporal. De esta manera, se establecen bloques nominales de entrenamiento, validación y prueba en proporciones temporales de 60/20/20.

Después de cada punto de corte se excluye un intervalo de aproximadamente un segundo. Estas observaciones se identifican como guard y no se utilizan para ajustar las transformaciones ni para evaluar los bloques posteriores.

La separación responde a la naturaleza secuencial de los datos: las observaciones cercanas en el tiempo comparten información y no deben distribuirse aleatoriamente como si fueran independientes. La guarda de un segundo supera la ventana histórica de 0.2 segundos utilizada en esta demostración, pero no garantiza independencia estadística entre bloques. Si posteriormente se emplean historias o horizontes predictivos más largos, deberá revisarse su duración.

En este avance, los términos entrenamiento, validación y prueba describen bloques destinados a demostrar el ajuste y la aplicación de la ingeniería de características. No se ha entrenado un modelo predictivo.

Los parámetros de imputación, escalamiento, selección y PCA se estimarán exclusivamente con el bloque de entrenamiento. Una vez ajustados, se aplicarán sin recalibración a validación y prueba. Este procedimiento reduce el riesgo de que la preparación incorpore información de los bloques utilizados para evaluación (scikit-learn developers, s. f.-a).

Resultados de la codificación

La salida muestra que los roles y el lado se expresan mediante valores binarios. En los primeros registros, un portero del equipo local presenta role_Goalkeeper = 1 y side_home = 1, mientras que las demás categorías de rol y side_away toman el valor 0.

Los registros siguientes de defensores locales activan role_Defender y side_home. Esta comprobación ilustra el funcionamiento de la codificación, sin atribuir a las categorías un orden de habilidad ni comprobar todavía su utilidad predictiva.

La condición starter = True de estos ejemplos indica que los jugadores figuran como titulares en las alineaciones. No constituye una etiqueta de participación válida para todos los instantes del partido.

Resultados de la separación temporal

Las 8,999 observaciones conservadas se distribuyeron de la siguiente manera:

Tabla 6. Distribución temporal de los bloques de datos

Bloque	Observaciones	Tiempo inicial	Tiempo final
Entrenamiento	5,401	0.000057 s	107.991439 s
Validación	1,747	109.011380 s	143.968610 s
Prueba	1,750	145.008521 s	179.985746 s
Guardas temporales	101	Dos intervalos separados	Dos intervalos separados

Fuente: Elaboración propia.

Las 101 observaciones de guarda se encuentran después de los dos puntos de corte. Aunque la salida agrupada informa un mínimo de 108.011462 segundos y un máximo de 144.988527 segundos para guard, estos valores corresponden a los extremos de dos intervalos distintos. No describen una exclusión continua entre ambos tiempos.

Las cantidades de observaciones no siguen exactamente una proporción de 60/20/20 porque los cortes se establecen por tiempo, se excluyen las guardas y previamente se retiraron observaciones durante la revisión de calidad.

Riesgos de sesgo y alcance de la evaluación

La selección de los tres minutos iniciales introduce una limitación de cobertura. La muestra no permite caracterizar el conjunto de situaciones del partido ni asegurar representación de fases posteriores, fatiga, sustituciones o diferentes condiciones tácticas.

Las observaciones de juego detenido se conservan junto con su contexto. Su eventual exclusión o análisis separado dependerá de la tarea predictiva que se defina y del significado confirmado de los campos del proveedor.

La evaluación posterior deberá utilizar partidos separados y documentar la presencia de jugadores y equipos compartidos entre particiones. Separar partidos evita reutilizar fragmentos del mismo encuentro, pero no demuestra por sí solo generalización a jugadores o equipos no observados previamente.

La codificación y el escalamiento pueden reducir distorsiones derivadas de categorías mal representadas o unidades diferentes. Sin embargo, no corrigen automáticamente los sesgos de selección, la cobertura limitada o los errores de captura. Por ello, estas decisiones se acompañan de una delimitación explícita de la muestra y de controles de calidad, conforme al enfoque de preparación y aseguramiento de calidad de CRISP-ML(Q) (Visengeriyeva et al., 2023).

Finalmente, la separación temporal no resuelve las anomalías cinemáticas identificadas en la sección anterior. Su tratamiento deberá documentarse y, si modifica la tabla de características, se repetirá el ajuste de las transformaciones y las comprobaciones posteriores.

Implementación y salida completa: anexo A, código 5.

Transformación y escalamiento

La transformación y el escalamiento preparan las características numéricas para su utilización posterior en métodos sensibles a las diferencias de escala. El propósito es evitar que las unidades o magnitudes de una variable dominen el procesamiento, sin eliminar su significado ni interpretar el escalamiento como una corrección de errores de captura.

Las decisiones se ajustan exclusivamente con el bloque de entrenamiento definido en la sección anterior. Los parámetros obtenidos se conservan para aplicar el mismo procesamiento a validación y prueba, evitando recalcularlos con información de evaluación (scikit-learn developers, s. f.-a).

Evaluación de la transformación logarítmica

Se evalúa una transformación logarítmica del desplazamiento horizontal reciente, disp_0p2, debido a que esta variable es no negativa y puede presentar una distribución asimétrica. La expresión considerada es:

Desplazamiento transformado = ln(1 + disp_0p2 / 1 m)

La división entre un metro expresa el desplazamiento como una razón sin unidades. En el código, las coordenadas se manejan numéricamente en metros, por lo que la operación se implementa mediante log1p(disp_0p2).

La transformación se selecciona únicamente cuando se cumplen dos condiciones en las observaciones disponibles del bloque de entrenamiento:

1. La asimetría absoluta del desplazamiento original es superior a 1.

2. La transformación reduce esa asimetría absoluta.

El umbral de 1 constituye una regla operacional para esta demostración. No es una prueba de normalidad ni demuestra que una distribución transformada sea más útil para predecir jugadas.

No se aplica logaritmo directamente a coordenadas o componentes de velocidad que pueden tomar valores negativos. Tampoco se establece la normalidad de todas las características como requisito para una futura GNN. La transformación debe responder a las propiedades de la variable y al método que se utilizará posteriormente (scikit-learn developers, s. f.-c).

Tratamiento de valores faltantes

Antes del escalamiento se identifican los valores faltantes y se reemplazan los valores infinitos por faltantes para su tratamiento explícito. Los valores numéricos ausentes se imputan mediante la mediana de cada variable calculada exclusivamente con entrenamiento.

Para las características continuas se incorporan columnas indicadoras de ausencia. Estas máscaras permiten distinguir un valor observado de uno completado durante el procesamiento. En particular, una velocidad o un cambio de rapidez imputados no se interpretan como movimiento medido.

Los indicadores de disponibilidad de contexto, como in_play_known e in_bounds_known, se conservan junto con los estados codificados. Así, la imputación de un estado desconocido no elimina la información de que el registro original estaba ausente o no era reconocido.

La imputación completa la matriz numérica para los procedimientos posteriores, pero no recupera una observación física perdida. Su utilidad deberá comprobarse durante la evaluación del modelo, considerando la frecuencia y las causas de los faltantes.

Estandarización de las características continuas

Las variables continuas se estandarizan mediante la expresión:

$z = (x - \mu_{entrenamiento}) / \sigma_{entrenamiento}$

En esta expresión, x es el valor de la característica después de la transformación e imputación correspondientes; $\mu_{entrenamiento}$ es su media y $\sigma_{entrenamiento}$ su desviación estándar poblacional, calculadas con el bloque de entrenamiento.

La estandarización busca producir variables con media cercana a cero y desviación cercana a uno en entrenamiento. Esta escala facilita su comparación numérica y prepara las entradas para técnicas como PCA. No obliga a que la distribución sea normal ni garantiza una contribución predictiva equivalente de todas las características (scikit-learn developers, s. f.-c).

Las variables binarias y las columnas one-hot conservan sus valores 0/1. Las máscaras de ausencia tampoco se estandarizan. Si una variable continua presenta una desviación prácticamente nula, la implementación utiliza un divisor de 1 para evitar una división por cero; su posible exclusión se examina posteriormente mediante el filtro de varianza.

Las posiciones x_relative e y_relative pasan por dos operaciones diferentes. Primero se expresan respecto a las dimensiones provisionales de la cancha y después se estandarizan junto con las demás variables continuas de la matriz tabular. La primera operación establece una referencia espacial; la segunda utiliza estadísticas de entrenamiento. Las coordenadas originales se conservan en la tabla de características.

Las fórmulas se implementan mediante NumPy y pandas, manteniendo explícitos los parámetros de cada operación y reduciendo las dependencias necesarias para ejecutar la demostración.

Resultados de la transformación

La comparación realizada en entrenamiento produjo los siguientes resultados:

Tabla 7. Comparación de asimetría antes y después de log1p

Indicador	Desplazamiento original	Desplazamiento con log1p
Asimetría	0.966	0.2243

Fuente: Elaboración propia.

Aunque el logaritmo redujo la asimetría, el valor original no superó el umbral operacional de 1. Por tanto, la transformación no se seleccionó y la variable disp_feature conservó el desplazamiento sin transformar.

Esta decisión evita aplicar una operación únicamente porque está disponible. Su elección deberá revisarse si cambia la muestra, se modifica el tratamiento de calidad o se obtienen evidencias de utilidad para el modelo.

Resultados del escalamiento

Se estandarizaron las 13 características continuas: posiciones relativas, altura, componentes de velocidad, rapidez planar, velocidad del proveedor, cambio de rapidez, desplazamiento reciente, distancia al centro y componentes de dirección.

Tabla 8. Comprobaciones de estandarización en entrenamiento

Comprobación en entrenamiento	Resultado
Media de las características estandarizadas	Aproximadamente 0
Desviación estándar mostrada en la salida	Aproximadamente 1.0001
Transformación logarítmica seleccionada	No
Observaciones de la matriz candidata	8,999
Columnas de la matriz candidata	40

Fuente: Elaboración propia.

La diferencia entre 1 y 1.0001 responde al criterio de cálculo de la desviación estándar. La estandarización utiliza la desviación poblacional, con divisor n, mientras que la comprobación mostrada calcula la desviación muestral, con divisor n − 1. Los resultados son consistentes con el procedimiento aplicado.

Los valores impresos como −0.0000 corresponden a cantidades numéricas muy pequeñas y al redondeo de la salida. No representan una diferencia sustantiva respecto de cero.

La matriz candidata de 8,999 filas y 40 columnas reúne características numéricas, indicadores de ausencia y variables contextuales codificadas. La codificación de roles de las alineaciones, presentada en la sección anterior, permanece como un componente separado para la posterior integración de jugadores.

Limitaciones y controles pendientes

La estandarización no corrige las velocidades y los cambios de rapidez extremos identificados durante la construcción de características. Estas observaciones permanecen en la versión actual y pueden influir en las medias y desviaciones utilizadas.
Por ello, los resultados de escalamiento se consideran provisionales respecto del control cinemático pendiente. Una vez documentado el tratamiento de las observaciones señaladas, deberán recalcularse las características afectadas y reajustarse los parámetros utilizando únicamente entrenamiento. Si se requiere comparar alternativas menos sensibles a valores extremos, esa decisión deberá fundamentarse con los datos y mantener la interpretación física de las variables.

La contribución de esta sección consiste en documentar una transformación evaluada, justificar su no aplicación y ejecutar un escalamiento reproducible con tratamiento explícito de faltantes. La comprobación de mejoras de convergencia o desempeño corresponde a una fase posterior de entrenamiento y evaluación.

Implementación y salida completa: anexo A, código 6.

Selección por filtrado y extracción de características

Después de preparar la matriz numérica, se evalúan operaciones de selección y extracción para reducir su dimensionalidad y examinar la redundancia entre variables. Se comparan dos representaciones: una matriz filtrada que conserva características identificables y una representación comprimida de las variables continuas mediante análisis de componentes principales.

Los filtros y PCA se ajustan exclusivamente con el bloque de entrenamiento. Sus decisiones y parámetros se aplican posteriormente a validación y prueba, sin recalcularlos con esos bloques, para prevenir fugas de información (scikit-learn developers, s. f.-a).

Selección mediante varianza

El primer filtro identifica columnas cuya varianza en entrenamiento es menor o igual a 1×10^{-12}. El umbral permite detectar variables constantes o prácticamente constantes bajo la precisión numérica utilizada.

Una columna constante no distingue observaciones dentro del bloque analizado. Por ello, se excluye de la representación tabular experimental. Este criterio constituye un filtro no supervisado: examina la variación de las entradas, pero no mide su relación con un resultado predictivo (scikit-learn developers, s. f.-b).

La exclusión se limita a la representación experimental. Una categoría o máscara constante en los primeros minutos puede variar posteriormente, por lo que se conserva su definición en el esquema completo de características para revisar su utilidad al incorporar más partidos.

Selección mediante correlación

El segundo filtro calcula la correlación de Pearson entre las columnas restantes, utilizando únicamente entrenamiento. Se consideran candidatas a exclusión las variables cuya correlación absoluta con una columna ya conservada sea igual o superior a 0.95.

El valor absoluto permite detectar asociaciones lineales positivas y negativas. Por ejemplo, dos indicadores pueden contener información complementaria y presentar una correlación negativa cercana a -1.

La selección sigue el orden documentado de las columnas: posición, cinemática, contexto, máscaras y categorías. Cuando se alcanza el umbral, se conserva la primera columna y se registra la variable excluida, la columna conservada y la magnitud de su correlación.

Esta regla hace reproducible la selección, pero no establece que la primera variable sea más útil para predecir. Asimismo, una correlación elevada no demuestra equivalencia exacta, y Pearson no identifica todas las relaciones no lineales. El umbral de 0.95 se considera una decisión operacional que deberá revisarse con más datos.

Resultados del filtrado

El filtro de varianza excluyó ocho columnas constantes en entrenamiento:

- in_play_known
- in_bounds_known
- x_relative_missing
- y_relative_missing
- z_missing
- speed_provider_mps_missing
- center_distance_missing
- zone_unknown

La constancia de estas columnas describe únicamente el bloque utilizado para ajustar el filtro. No demuestra que los correspondientes estados o faltantes estén ausentes en el resto del partido.

El filtro de correlación excluyó siete columnas adicionales:

Tabla 9. Variables excluidas por correlación perfecta

Variable excluida	Variable conservada	Correlación absoluta
vy_missing	vx_missing	1.000000
vz_missing	vx_missing	1.000000
speed_planar_missing	vx_missing	1.000000
heading_sin_missing	heading_valid	1.000000
heading_cos_missing	heading_valid	1.000000
possession_away	possession_home	0.991879
possession_unknown	known_possession	1.000000

Fuente: Elaboración propia.

Las coincidencias entre algunas máscaras responden a que sus variables comparten condiciones de cálculo. En otros casos, la relación se produce entre indicadores complementarios.

La exclusión de possession_away requiere especial cautela: su correlación con possession_home es elevada, pero no perfecta. Por tanto, no se presupone que una columna permita reconstruir exactamente la otra. Esta decisión se mantendrá como parte de la comparación experimental y deberá revisarse según la tarea predictiva y la cobertura de estados.

Tabla 10. Reducción de columnas durante el filtrado

Etapa	Columnas
Matriz candidata	40
Después del filtro de varianza	32
Después del filtro de correlación	25

Fuente: Elaboración propia.

El filtrado redujo la matriz en 15 columnas, equivalentes al 37.5 % de las columnas candidatas. Las 13 características continuas permanecieron disponibles; las exclusiones correspondieron a indicadores, máscaras y categorías.

Extracción mediante PCA

Se aplica análisis de componentes principales mediante descomposición en valores singulares, o SVD, sobre las 13 características continuas previamente estandarizadas. La matriz se centra utilizando la media de entrenamiento y se obtienen componentes que combinan linealmente las variables originales.

Se selecciona el menor número de componentes cuya varianza explicada acumulada alcance al menos el 95 % en entrenamiento. Las columnas binarias, las máscaras y las categorías no se incorporan a esta extracción.

PCA proporciona una representación de menor dimensión que conserva una proporción definida de la variación de las entradas. Esa variación no equivale necesariamente a información útil para predecir jugadas; por ello, se mantiene también la alternativa interpretable sin PCA (Jolliffe & Cadima, 2016).

La extracción se utiliza como una rama de preparación tabular. No reemplaza la estructura de nodos y aristas de una GNN ni identifica, por sí sola, patrones tácticos.

Resultados de la extracción

El criterio establecido seleccionó diez componentes a partir de las 13 variables continuas.

Tabla 11. Resultados de la extracción mediante PCA

Indicador	Resultado
Variables continuas de entrada	13
Componentes conservados	10
Varianza acumulada de entrenamiento	96.186 %
Reducción de la dimensión continua	23.08 %

Fuente: Elaboración propia.

Los coeficientes de cada componente se conservan en la salida para documentar cómo se combinan las variables. Por ejemplo, el primer componente presenta coeficientes de mayor magnitud en speed_planar, disp_feature y speed_provider_mps. Esta observación describe la combinación numérica obtenida; no permite asignarle automáticamente un significado táctico.

El signo de un componente puede invertirse sin modificar la representación equivalente ni la reconstrucción. Por tanto, sus coeficientes no deben interpretarse como efectos causales de las características sobre una jugada.

La tabla completa de coeficientes se incluye en el anexo A, código 7.

Error de reconstrucción

Se reconstruyen las variables continuas a partir de los diez componentes y se calcula el error cuadrático medio, MSE, respecto de la matriz continua estandarizada e imputada.

Tabla 12. Error de reconstrucción por bloque temporal

Bloque	MSE de reconstrucción
Entrenamiento	0.038137
Validación	0.073597
Prueba	0.090910

Fuente: Elaboración propia.

Estos valores describen la pérdida de información numérica producida por la compresión. No representan errores de predicción de trayectorias ni están expresados en metros.

El error aumenta en los bloques posteriores. Este resultado muestra que la representación ajustada en entrenamiento reconstruye con menor precisión esas observaciones, pero no permite determinar por sí solo la causa. Será necesario revisar la variación temporal, las observaciones extremas y la estabilidad de los componentes con muestras adicionales.

La reconstrucción se compara contra datos ya imputados; por ello, tampoco evalúa si la imputación recuperó correctamente los valores físicos ausentes.

Requerimientos de memoria de las representaciones

Se comparó el tamaño de las matrices NumPy utilizando las mismas 8,999 observaciones y valores de tipo float64.

Tabla 13. Tamaño de las representaciones de datos

Representación	Tamaño en bytes
Matriz candidata de 40 columnas	2,879,680
Matriz filtrada de 25 columnas	1,799,800
Matriz continua de entrada a PCA	935,896
Matriz de diez componentes PCA	719,920

Fuente: Elaboración propia.

La matriz filtrada requiere un 37.5 % menos de memoria numérica que la candidata. La representación PCA requiere aproximadamente un 23.08 % menos que su entrada continua.

Estas comparaciones corresponden únicamente a los valores almacenados en las matrices. No incluyen índices, nombres de columnas, parámetros de transformación, estructuras auxiliares ni archivos comprimidos. Tampoco demuestran una reducción del tiempo de entrenamiento.

Los diez componentes representan solo la parte continua: si se combinan con los indicadores no continuos de la matriz filtrada, esa representación conservaría 22 columnas. Esta combinación no se reporta como una matriz final ya construida en la ejecución mostrada.

Métodos no seleccionados y limitaciones

No se aplican ANOVA ni chi-cuadrado para selección supervisada porque todavía no se dispone de una etiqueta validada de jugada. Adicionalmente, chi-cuadrado requiere entradas no negativas compatibles con su formulación, condición que no cumplen todas las variables estandarizadas. Esta restricción no se atribuye a ANOVA (scikit-learn developers, s. f.-b).

El análisis factorial tampoco se selecciona, ya que requeriría justificar un modelo de factores latentes y su adecuación a las variables. La elección de métodos responde a las características y objetivos de la muestra, en lugar de aplicar todas las técnicas ilustrativas de la actividad.

Finalmente, la correlación y PCA pueden verse afectadas por las anomalías cinemáticas identificadas previamente. Los resultados presentados documentan la ejecución actual, pero deberán recalcularse si cambia el tratamiento de esas observaciones.

Esta fase proporciona evidencia de reducción de dimensionalidad y procedimientos reproducibles de selección y extracción. La utilidad predictiva de las representaciones y su efecto sobre la complejidad del modelo se comprobarán en la fase posterior de entrenamiento y evaluación.

Implementación, coeficientes y salida completa: anexo A, código 7.

Preparación de una representación en grafos para GNN

La preparación en grafos busca representar cada instante del juego mediante entidades y relaciones, de manera que un modelo posterior pueda analizar la interacción entre jugadores y balón. Esta representación complementa las características tabulares construidas previamente y permite organizar información individual y relacional.

Se implementa un constructor que produce atributos de nodos, índices de conexiones y atributos de aristas. Su estructura es compatible con el enfoque de paso de mensajes, en el que las representaciones de los nodos se actualizan utilizando información de sus vecinos y conexiones (Gilmer et al., 2017).

La referencia fundamenta el formalismo de representación y procesamiento de grafos. Sus resultados corresponden al dominio de química y no se presentan como evidencia de desempeño en fútbol.

Definición de nodos y conexiones

Se propone representar a los jugadores y al balón como nodos. Para cada instante se construye inicialmente un grafo dirigido completo, sin autoaristas: cada entidad se conecta con todas las demás, pero no consigo misma.

Para un grafo con N nodos, el número de aristas dirigidas es:

$E = N \times (N - 1)$

Si están disponibles 22 jugadores y un balón:

$N = 23$ nodos

$E = 23 \times 22 = 506$ aristas dirigidas

Esta cantidad describe el diseño teórico, no un grafo observado en la ejecución actual. El número real de nodos dependerá de las entidades presentes y válidas en cada instante.

Las entidades se ordenan de manera determinista por tipo e identificador. Este orden facilita reproducir la correspondencia entre filas de atributos e índices de aristas. Como la presencia de jugadores puede cambiar, las secuencias deberán conservar los identificadores para relacionar entidades entre instantes, sin asumir que una fila representa siempre al mismo jugador.

El grafo completo se utiliza como punto de partida porque permite representar todas las relaciones sin seleccionar previamente un radio de proximidad. Su cantidad de conexiones crece de forma cuadrática con el número de nodos; posteriormente podrá compararse con alternativas basadas en los k vecinos más cercanos.

Una arista expresa una relación disponible para el procesamiento del modelo. No constituye una etiqueta de pase, marcaje, presión o interacción observada.

Atributos de los nodos

Cada nodo incorpora características de posición, movimiento y tipo de entidad.

Tabla 14. Atributos de nodo para la construcción de grafos

Grupo	Atributos	Propósito
Posición	x_relative, y_relative	Representar la ubicación respecto de las dimensiones provisionales del terreno.
Movimiento	vx_causal, vy_causal	Describir el desplazamiento horizontal utilizando información disponible hasta el instante analizado.
Disponibilidad	motion_known	Indicar si ambas componentes de velocidad están disponibles.
Tipo de entidad	is_ball	Distinguir el balón de los jugadores.
Rol	Indicadores one-hot	Incorporar el rol registrado, con una categoría desconocida.

Fuente: Elaboración propia.

Los identificadores se conservan para vincular registros y organizar las secuencias, pero quedan fuera de la matriz numérica de atributos.

En la implementación, las velocidades ausentes se representan numéricamente con cero y se acompañan de motion_known = 0. Esta combinación distingue una velocidad no disponible de una observación de reposo. El cero utilizado para completar la matriz no se interpreta como una medición física.

No se reutilizan como entradas las velocidades ni la orientación combinada precalculadas para los jugadores, porque su procesamiento original incluye información posterior al instante observado. La función recalcula la cinemática mediante operaciones causales.

Atributos de las aristas

Para cada conexión dirigida desde una entidad de origen hacia una entidad de destino se calculan los siguientes atributos:

Tabla 15. Atributos de relación para la construcción de grafos

Atributo	Construcción	Información representada
dx_relative, dy_relative	Posición relativa del destino menos posición relativa del origen	Separación espacial y orientación de la relación.
dvx, dvy	Velocidad del destino menos velocidad del origen	Diferencia entre los movimientos de ambas entidades.
distance_relative	Distancia horizontal dividida entre la longitud provisional de la cancha	Magnitud de la separación espacial.
same_team	1 cuando ambos identificadores de equipo están disponibles y coinciden	Relación de pertenencia al mismo equipo.
involves_ball	1 cuando alguno de los extremos es el balón	Identificación de relaciones jugador–balón.
motion_known	1 cuando ambos nodos tienen cinemática disponible	Validez de la diferencia de velocidades.

Fuente: Elaboración propia.

Las diferencias se calculan como destino menos origen, por lo que invertir la dirección de una arista cambia el signo de sus componentes relativas. La distancia permanece igual.

Cuando una velocidad no está disponible, su diferencia numérica puede incluir el cero utilizado para completar el nodo. La máscara de la arista deberá utilizarse para impedir que esa diferencia se interprete como una relación de movimiento completamente observada.

Cálculo causal de la velocidad

La cinemática se recalcula por entidad, periodo y segmento temporal. Los segmentos se interrumpen cuando cambia la identidad, cambia el periodo, el tiempo no avanza o el intervalo supera el umbral configurado respecto de la frecuencia de muestreo.

Para jugadores, las posiciones se suavizan mediante una media histórica que incluye la observación actual y las anteriores. Después se estima la velocidad con una diferencia hacia atrás y el intervalo temporal real. Este procedimiento evita utilizar posiciones posteriores como entradas de una predicción (scikit-learn developers, s. f.-a).

Con una frecuencia configurada de 25 Hz, la ventana nominal de 0.2 segundos utiliza cinco observaciones. En una secuencia regular, la separación entre la primera y la última es aproximadamente 0.16 segundos. La función permite calcular la cantidad de observaciones según la frecuencia configurada, que deberá coincidir con la frecuencia efectiva del archivo.

Al inicio de un segmento pueden utilizarse ventanas históricas más cortas. Esta condición deberá documentarse y considerarse durante la validación de la cinemática.

Para el balón se utiliza diferencia hacia atrás sin aplicar esa media de posiciones, con el propósito de conservar los cambios rápidos disponibles en el registro. Esta decisión mantiene pendiente la revisión de las anomalías cinemáticas identificadas en las secciones anteriores.

Contexto y organización temporal

Cada grafo conserva el periodo, el frame y el identificador de posesión registrado por el proveedor. En la implementación actual, estos valores se almacenan como metadatos; no forman todavía un vector de contexto global codificado y escalado para la GNN.

La dirección de ataque inferida retrospectivamente y la estimación de portador por proximidad no se utilizan como etiquetas validadas ni como entradas definitivas del constructor.

Para representar episodios será necesario agrupar los grafos en secuencias temporalmente continuas, mantener la correspondencia de entidades y definir las ventanas históricas y los horizontes de predicción. Ese ensamblaje temporal constituye una ampliación posterior; el constructor actual prepara grafos de instantes individuales.

Escalamiento y controles de construcción

Las posiciones y distancias se expresan mediante las dimensiones provisionales del terreno. Las velocidades y sus diferencias permanecen en unidades físicas y todavía requieren una decisión de escalamiento para su incorporación al modelo.

Los parámetros estadísticos de ese escalamiento deberán ajustarse únicamente con los grafos de entrenamiento y conservarse al procesar validación y prueba. Los parámetros calculados con la muestra del balón no se transferirán automáticamente a las velocidades de jugadores.

La función incluye comprobaciones de columnas requeridas, identidad y clave temporal, presencia del balón y disponibilidad de posiciones. También verifica la estructura de los índices y que las matrices producidas contengan valores finitos. Estas comprobaciones forman parte de la implementación, pero no han sido validadas mediante una ejecución con el seguimiento real de jugadores.

Estado de implementación y resultado de ejecución

La ejecución del código 8 produjo el siguiente mensaje:

Pendiente: no se proporcionó el Parquet de jugadores; constructor definido, sin grafo colectivo ejecutado.

Por tanto, este avance entrega una implementación para preparar atributos de nodos y aristas, pero no presenta un grafo colectivo real ni resultados de entrenamiento de una GNN.

Para completar su validación será necesario disponer del archivo de seguimiento, verificar identidades, tiempos, unidades y frecuencia, y ejecutar el constructor sobre instantes con jugadores y balón. También deberán comprobarse los roles, la cobertura de entidades, las máscaras de cinemática y la organización posterior de secuencias.

Este estado se documenta como una limitación de la preparación, manteniendo la separación entre diseño, implementación y evidencia ejecutada dentro del aseguramiento de calidad de CRISP-ML(Q) (Visengeriyeva et al., 2023).

Implementación y mensaje de ejecución: anexo A, código 8.

Verificaciones y resultados reproducibles

La preparación concluye con comprobaciones de consistencia del código y el almacenamiento de los resultados y parámetros utilizados. Estas operaciones permiten revisar cómo se obtuvieron las características y repetir el procesamiento sobre las mismas fuentes.

Las verificaciones evalúan propiedades concretas de la implementación. No demuestran utilidad táctica, precisión predictiva ni ausencia de todos los posibles errores del conjunto. Documentar su alcance permite mantener trazabilidad y delimitar los riesgos pendientes dentro del aseguramiento de calidad de CRISP-ML(Q) (Visengeriyeva et al., 2023).

Verificación de causalidad mediante truncamiento

Se comprueba que las características históricas del balón no dependan de observaciones posteriores. Para ello, se recalculan utilizando únicamente las primeras 1,000 observaciones conservadas y se comparan con los valores obtenidos para esas mismas observaciones al procesar la muestra completa.

La comparación incluye componentes de velocidad, rapidez horizontal, cambio de rapidez, desplazamiento reciente, componentes de dirección y cambio de posesión registrada. Los valores coinciden dentro de las tolerancias numéricas de la comprobación, considerando también la correspondencia de los faltantes.

Este resultado respalda que las características examinadas mantienen su valor al retirar las observaciones posteriores del prefijo utilizado. No valida automáticamente todas las operaciones de la libreta, la selección del modelo o el constructor de grafos de jugadores, que permanece pendiente de ejecución.

La comprobación complementa la separación entre ajuste y evaluación: las características deben respetar la información disponible en el instante de predicción y los parámetros aprendidos deben proceder exclusivamente de entrenamiento (scikit-learn developers, s. f.-a).

Verificación numérica de PCA

Se realizan dos comprobaciones sobre la extracción mediante PCA:

- Ortogonalidad: se verifica que los vectores de los componentes conservados sean ortonormales dentro de la tolerancia numérica establecida.

- Consistencia entre formulaciones: se comparan los autovalores de la matriz de covarianza con las cantidades obtenidas a partir de los valores singulares, utilizando el mismo centrado y criterio de cálculo.

Ambas comprobaciones fueron satisfactorias. Respaldan la consistencia numérica de la implementación por SVD, conforme a la relación entre descomposición de la matriz de datos y análisis de su covarianza (Jolliffe & Cadima, 2016).

No evalúan si los componentes conservan información relevante para anticipar una jugada. Tampoco corrigen el efecto de las observaciones cinemáticas extremas; PCA puede estar implementado correctamente y, aun así, requerir un nuevo ajuste cuando cambie el tratamiento de calidad.

Comprobación de valores finitos

Se verifica que la matriz candidata, después de imputar y escalar, no contenga valores faltantes o infinitos. La comprobación fue satisfactoria y permite utilizar esa matriz en los procedimientos numéricos ejecutados.

Esta condición es necesaria para el procesamiento, pero no garantiza que todos los valores sean físicamente válidos. Una velocidad extrema puede ser finita y continuar requiriendo revisión. Por ello, la comprobación numérica se mantiene separada del control de plausibilidad cinemática.

Archivos generados y trazabilidad

Los resultados se almacenan en una carpeta independiente de las fuentes originales. La ejecución genera los siguientes archivos:

Tabla 16. Archivos generados y finalidad

Archivo	Contenido y finalidad
caracteristicas_balon.csv	Observaciones conservadas, características construidas y asignación de bloques temporales. Mantiene los faltantes anteriores a la imputación.
matriz_filtrada.csv	Representación tabular procesada después de imputación, escalamiento y filtrado, con la identificación del bloque temporal.
componentes_pca.csv	Valores de los diez componentes por observación y bloque temporal. Representa la parte continua comprimida.
duplicados_en_cuarentena.csv	Las dos observaciones excluidas por presentar contenido diferente bajo una misma clave temporal redondeada.
parametros_y_resultados.json	Fuentes y huellas SHA-256, configuración, controles de calidad, parámetros estadísticos, decisiones de filtrado, parámetros PCA, resultados y versiones del entorno.

Fuente: Elaboración propia.

La matriz filtrada y los componentes PCA corresponden a alternativas de representación. Su generación no establece una arquitectura definitiva ni implica que los componentes sustituyan toda la información contextual.

El archivo de parámetros registra medianas, medias, desviaciones, variables conservadas y parámetros de PCA. Esta información permite reconstruir el procesamiento aplicado, siempre que se mantengan el mismo esquema y orden de operaciones. Para utilizarlo posteriormente será necesario implementar una rutina que lea y aplique esos parámetros sin reajustarlos con evaluación.

La configuración documentada en la libreta, las versiones del entorno y las huellas de los archivos complementan esa trazabilidad. Registrar versiones y parámetros facilita comprobar la consistencia del procedimiento en otras ejecuciones.

Resumen de resultados ejecutados

Tabla 17. Resumen de resultados reproducibles

Indicador	Resultado
Observaciones conservadas	8,999
Variables continuas utilizadas	13
Columnas de la matriz candidata	40
Columnas de la matriz filtrada	25
Componentes PCA conservados	10
Comprobación de causalidad sobre el prefijo del balón	Satisfactoria
Comprobaciones numéricas de PCA	Satisfactorias
Matriz candidata con valores finitos	Verificada
Grafo colectivo ejecutado con jugadores	No

Fuente: Elaboración propia.

Las 13 variables continuas no se presentan como 13 características completamente nuevas: incluyen atributos originales, como la altura y la velocidad del proveedor, junto con variables derivadas.

La ejecución utiliza archivos locales previamente disponibles. No descarga datos, no requiere credenciales y no publica archivos en el repositorio. La incorporación de los resultados al repositorio constituye una operación posterior, sujeta a las condiciones de uso de los datos del proyecto.

Alcance de las verificaciones

Las comprobaciones realizadas respaldan la reproducibilidad del procesamiento de la muestra y la consistencia de las operaciones examinadas. Los controles pendientes incluyen la revisión de anomalías cinemáticas, la confirmación de las convenciones espaciales y temporales y la ejecución de los grafos con seguimiento real de jugadores.

Si el tratamiento de calidad modifica las observaciones o características, se repetirá la ejecución secuencial y se actualizarán los parámetros, las representaciones y sus comprobaciones. Por tanto, los resultados actuales constituyen evidencia de preparación de datos y no resultados de desempeño de un modelo de fútbol.

Implementación y salida completa: anexo A, código 9.

Conclusiones de la preparación de datos en CRISP ML Q

La fase de preparación permitió transformar una muestra real de seguimiento del balón en una representación reproducible de características cinemáticas, históricas, espaciales y contextuales. El procesamiento conservó 8,999 observaciones de los tres archivos iniciales del partido Genoa–Napoli y documentó las fuentes, los controles de calidad, las decisiones de transformación y los parámetros utilizados.

La construcción de características respondió al objetivo de representar el movimiento y el contexto disponible hasta cada instante. La codificación permitió organizar variables nominales sin introducir jerarquías artificiales, mientras que la separación temporal estableció bloques para ajustar las transformaciones exclusivamente con entrenamiento. La comprobación por truncamiento respaldó la causalidad de las características examinadas en el prefijo del balón, sin extender esa conclusión a procedimientos todavía pendientes de ejecución.

El escalamiento atendió las diferencias de magnitud entre variables continuas y conservó indicadores de disponibilidad. La transformación logarítmica del desplazamiento se evaluó, pero no se seleccionó porque la asimetría original no superó el umbral operacional establecido. Estas decisiones se justificaron con las propiedades observadas de la muestra, en lugar de aplicar técnicas únicamente por estar disponibles.

La selección por varianza y correlación redujo la matriz candidata de 40 a 25 columnas. Por su parte, PCA condensó las 13 variables continuas en diez componentes que conservaron aproximadamente el 96.19 % de la varianza de entrenamiento. Estos resultados demuestran reducción de dimensionalidad en la representación examinada; no prueban que se conserve toda la información predictiva ni que disminuya el tiempo de entrenamiento.

La reducción de memoria reportada corresponde exclusivamente a matrices numéricas con las mismas observaciones. No se midió ahorro de almacenamiento del conjunto completo, mejora de precisión ni convergencia de una GNN, porque este avance no incluyó entrenamiento de modelos.

En CRISP-ML(Q), la preparación comprende la construcción de entradas consistentes y reproducibles, acompañada de la identificación de riesgos y controles de calidad (Visengeriyeva et al., 2023). Bajo este enfoque, el resultado del avance es un procedimiento ejecutado sobre una muestra acotada, junto con evidencia de sus verificaciones y condiciones explícitas para continuar. No se considera concluida la preparación del conjunto completo ni se declara que todas las características estén listas para modelar.

El control pendiente más inmediato es revisar las velocidades y los cambios de rapidez extremos identificados durante la construcción de características. La imputación y la estandarización no corrigen esas posibles inconsistencias. Una vez definido su tratamiento, deberán repetirse los cálculos afectados, el ajuste de las transformaciones y las comprobaciones de selección y PCA.

También será necesario confirmar las dimensiones físicas del terreno, la convención temporal entre periodos y el significado de los estados del proveedor. Las categorías y máscaras excluidas por constancia local permanecerán definidas en el esquema de preparación hasta evaluar su comportamiento en muestras más amplias.

La representación mediante grafos quedó implementada como constructor de atributos de nodos y aristas, pero su ejecución sobre interacciones reales depende del seguimiento de jugadores. Su validación deberá comprobar identidad, cobertura, frecuencia de muestreo y continuidad, además de separar la dirección del movimiento, la orientación corporal y las estimaciones de portador. La posesión registrada a nivel de equipo no se considerará equivalente a control individual ni a una etiqueta validada de pase o recuperación.

La siguiente fase deberá definir una tarea y un horizonte predictivo, comparar representaciones básicas y enriquecidas y evaluar sus resultados en partidos separados. Ese análisis permitirá establecer qué características aportan información útil, cuáles resultan redundantes y qué representación ofrece un equilibrio adecuado entre interpretación, complejidad y desempeño.

En consecuencia, el avance cumple una función de preparación: establece cómo construir, transformar, seleccionar y documentar características con los datos disponibles, y deja delimitadas las verificaciones necesarias antes de utilizarlas para aprender y anticipar episodios futbolísticos.

Referencias

Gilmer, J., Schoenholz, S. S., Riley, P. F., Vinyals, O., & Dahl, G. E. (2017). Neural message passing for quantum chemistry. En D. Precup & Y. W. Teh (Eds.), Proceedings of the 34th International Conference on Machine Learning (Vol. 70, pp. 1263–1272). PMLR. https://proceedings.mlr.press/v70/gilmer17a.html

Jolliffe, I. T., & Cadima, J. (2016). Principal component analysis: A review and recent developments. Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences, 374(2065), 20150202. https://doi.org/10.1098/rsta.2015.0202

scikit-learn developers. (s. f.-a). Common pitfalls and recommended practices. scikit-learn. Recuperado el 9 de octubre de 2026, de https://scikit-learn.org/stable/common_pitfalls.html

scikit-learn developers. (s. f.-b). Feature selection. scikit-learn. Recuperado el 9 de octubre de 2026, de https://scikit-learn.org/stable/modules/feature_selection.html

scikit-learn developers. (s. f.-c). Preprocessing data. scikit-learn. Recuperado el 9 de octubre de 2026, de https://scikit-learn.org/stable/modules/preprocessing.html

Visengeriyeva, L., Kammer, A., Bär, I., Kniesz, A., & Plöd, M. (2023). CRISP-ML(Q): The ML lifecycle process. INNOQ. https://ml-ops.org/content/crisp-ml

Procedencia de los materiales del proyecto

Se utilizaron los archivos de seguimiento del balón y alineaciones proporcionados por Math & Sport, cuya identificación y huellas SHA-256 se registran en esta sección. Como documentación técnica interna se consultaron el procedimiento de conversión prepare_match.py, el README, CLAUDE.md, types.ts y meta.json, procedentes de la copia del repositorio privado del equipo revisada el 9 de octubre de 2026. Estos materiales permiten documentar el esquema de datos y las decisiones de procesamiento; las fuentes académicas y técnicas que fundamentan los métodos se presentan en el apartado de referencias.

Anexos del Avance 2
Ingeniería de características Equipo 52

Los anexos reúnen la implementación, las salidas comprobadas y la información necesaria para repetir la preparación de la muestra. Las referencias académicas se mantienen en la sección de referencias del informe; no se duplican aquí.

La copia revisada conserva los resultados numéricos reportados para el balón. Las observaciones cinemáticas extremas permanecen pendientes de revisión y los grafos colectivos no se han ejecutado con jugadores. Las cifras de escalamiento y PCA mantienen ese alcance provisional.

Anexo A Código y salidas de ejecución

Los nueve bloques siguientes deben ejecutarse en orden, en la misma sesión Python. Incluyen sus salidas completas de una ejecución secuencial en un proceso nuevo. Definir las funciones del código 8 no equivale a validarlas con un Parquet de jugadores; su rama opcional no se ejecutó.

El código es texto editable, conserva la indentación y utiliza una fuente monoespaciada para facilitar su lectura. Para ejecutarlo se recomienda la libreta, ya que copiar desde Word puede alterar espacios o comillas según las opciones del editor. El informe académico no ejecuta código.

Tabla 18. Correspondencia entre bloques de código y secciones

Bloque	Sección del informe	Contenido
1	1	Configuración y entorno
2	2	Alineaciones y fuentes
3	3	Lectura y calidad
4	4	Construcción de características
5	5	Codificación y separación
6	6	Transformación y escalamiento
7	7	Filtrado y PCA
8	8	Constructor GNN pendiente de datos
9	9	Verificaciones y exportación

Fuente: Elaboración propia.

Código 1 Configuración y localización de datos

```
import os, sys, json, re, zipfile, hashlib, platform
from pathlib import Path
import numpy as np
import pandas as pd
pd.set_option('display.max_columns', 20)
pd.set_option('display.width', 160)

MATCH = '2026-08-22_GENOA-NAPOLI'
```

```
MAX_MEMBERS = 3  # demostración: tres archivos ordenados por periodo/minuto
BASE_HZ = 50
MAX_GAP_S = 0.05  # segmentar huecos mayores a 2.5 intervalos nominales
GUARD_S = 1.0    # superior a la ventana histórica de 0.2 s
ROOTS = [Path.cwd(), *Path.cwd().parents]
configured = os.environ.get('AVANCE2_DATA_DIR')
candidates = ([Path(configured)] if configured else []) + [
    p / sub / MATCH for p in ROOTS for sub in ('datos', 'Descargas')]
DATA_DIR = next((p for p in candidates if (p/'matchLineups.json').is_file()
                 and (p/f'{MATCH}_scrubbed_ball_NOT_PARSED.zip').is_file()), None)
if DATA_DIR is None:
      raise FileNotFoundError('Coloque los dos archivos en datos/'+MATCH+' o configure
AVANCE2_DATA_DIR. Consulte README.md.')
OUT = Path.cwd()/'resultados_revision_anexos'
OUT.mkdir(exist_ok=True)
print('Python:', platform.python_version(), '| NumPy:', np.__version__, '| pandas:',
pd.__version__)
print('Partido:', MATCH, '| miembros a procesar:', MAX_MEMBERS, '| acceso AWS: no
utilizado')
```

Salida de la ejecución del código 1

```
Python: 3.12.14 | NumPy: 2.3.5 | pandas: 3.0.1
Partido: 2026-08-22_GENOA-NAPOLI | miembros a procesar: 3 | acceso AWS: no utilizado
```

Código 2 Trazabilidad y alineaciones

```
def sha256(path):
    h = hashlib.sha256()
    with path.open('rb') as f:
        for block in iter(lambda: f.read(1024*1024), b''):
            h.update(block)
    return h.hexdigest()

lineup_path = DATA_DIR/'matchLineups.json'
zip_path = DATA_DIR/f'{MATCH}_scrubbed_ball_NOT_PARSED.zip'
lineups = json.loads(lineup_path.read_text(encoding='utf-8-sig'))
provenance = {p.name:{'bytes':p.stat().st_size, 'sha256':sha256(p)} for p in
(lineup_path,zip_path)}
roster_rows = []
event_nonempty = 0
for side in ('home','away'):
    team = lineups[side]
    for status in ('fielded','benched'):
        for p in team.get(status) or []:
            event_nonempty += int(bool(str(p.get('events') or '').strip()))
            roster_rows.append({'entity_id':p.get('playerId'), 'team_id':team.get('teamId'),
```

```
                'side':side, 'role_label':p.get('roleLabel') or 'Unknown',
                'starter':status=='fielded', 'jersey_number':p.get('bibNumber')})
roster = pd.DataFrame(roster_rows)
assert roster.entity_id.notna().all() and not roster.entity_id.duplicated().any()
print('Equipos:',lineups['home']['shortName'],'vs',lineups['away']['shortName'])
print(roster.groupby(['side','starter']).size().rename('jugadores').to_string())
print('Campos events no vacíos en este archivo:',event_nonempty)
print('Dimensiones declaradas en alineaciones:',lineups.get('pitchSizeX'),lineups.get('pitchSizeY'))
print('Huella de fuentes:')
print(json.dumps(provenance,ensure_ascii=False,indent=2))
```

Salida de la ejecución del código 2

```
Equipos: Genoa vs Napoli
side  starter
away  False      13
      True       11
home  False      13
      True       11
Campos events no vacíos en este archivo: 21
Dimensiones declaradas en alineaciones: None None
Huella de fuentes:
{
  "matchLineups.json": {
    "bytes": 49178,
    "sha256": "daade4d82904fcbe27b5b429744d9d82c1b03063b0ec64453dc46e9acab0a6d1"
  },
  "2026-08-22_GENOA-NAPOLI_scrubbed_ball_NOT_PARSED.zip": {
    "bytes": 109396388,
    "sha256": "710a8aacb16676fcdca97afe57ec4ea16fe0f793a45cb87629d6d72a8eebbae4"
  }
}
```

Código 3 Lectura del balón y controles de calidad

La repetición examinada corresponde a una clave redondeada. El nombre histórico duplicados_en_cuarentena.csv identifica el archivo de revisión, sin afirmar duplicación de la captura original.

```
pattern = re.compile(r'_(\d+)_(\d+)\.football\.samples\.ball$')
rows, selected_members = [], []
with zipfile.ZipFile(zip_path) as archive:
    members = []
    for name in archive.namelist():
        match = pattern.search(name)
```

```
        if match:
            members.append((int(match[1]),int(match[2]),name))
    members.sort()
    print('Miembros reconocidos en ZIP:',len(members))
    for period,minute,name in members[:MAX_MEMBERS]:
        selected_members.append({'period':period,'minute':minute,'name':name})
        with archive.open(name) as handle:
            payload = json.load(handle)
        for s in payload.get('samples',{}).get('ball',[]):
            pos = s.get('pos') or [None,None,None]
            rows.append({'period':period,'minute':minute,
                't':(minute-1)*60+float(s['time']),
                'x':pos[0],'y':pos[1],'z':pos[2],
                'speed_provider_mps':(s.get('speed') or {}).get('mps'),
                            'possession_team_id':((s.get('possession') or {}).get('teamId') or
{}).get('serieAId'),
                'play':s.get('play'),'bounds':s.get('bounds')})
raw = pd.DataFrame(rows).sort_values(['period','t'],kind='stable').reset_index(drop=True)
raw['frame'] = np.rint(raw.t*BASE_HZ).astype('int64')
key = ['period','frame']
dup_mask = raw.duplicated(key,keep=False)
conflicts = 0
conflict_keys = []
for _,g in raw.loc[dup_mask].groupby(key):
                                                                                    if
g[['x','y','z','possession_team_id','play','bounds']].astype(str).drop_duplicates().shape[0]>1
:
        conflicts += 1
        conflict_keys.append(tuple(g.iloc[0][key]))
# Colisión de clave redondeada: cuarentena de ambas versiones, sin afirmar duplicado
original.
conflict_key_set = set(conflict_keys)
conflict_mask = pd.Series([tuple(v) in conflict_key_set for v in
raw[key].to_numpy()],index=raw.index)
raw.loc[conflict_mask].to_csv(OUT/'duplicados_en_cuarentena.csv',index=False)
duplicates = int(raw.duplicated(key).sum())
ball                                                                                =
raw.loc[~conflict_mask].drop_duplicates(key,keep='first').copy().reset_index(drop=True)
dt = ball.t.diff()
breaks = ball.period.ne(ball.period.shift()) | dt.le(0) | dt.gt(MAX_GAP_S)
ball['segment'] = breaks.cumsum()
quality = {'raw_rows':len(raw),'rows':len(ball),'duplicate_rows_detected':duplicates,

'conflicting_keys_quarantined':conflicts,'conflicting_rows_quarantined':int(conflict_mask.su
m()),
          'segments':int(ball.segment.nunique()),'median_dt_s':float(dt[~breaks].median()),
```

```
        'missing_xyz':ball[['x','y','z']].isna().sum().to_dict(),
        'time_min_s':float(ball.t.min()),'time_max_s':float(ball.t.max())}
print(json.dumps(quality,indent=2))
print('Estados play:',ball.play.value_counts(dropna=False).to_dict())
print('Estados bounds:',ball.bounds.value_counts(dropna=False).to_dict())
print(ball[['t','x','y','z','speed_provider_mps']].head(3).to_string(index=False))
assert not ball.duplicated(key).any()
assert ball.groupby('segment').t.apply(lambda x: x.diff().dropna().gt(0).all()).all()
```

Salida de la ejecución del código 3

```
Miembros reconocidos en ZIP: 97
{
  "raw_rows": 9001,
  "rows": 8999,
  "duplicate_rows_detected": 1,
  "conflicting_keys_quarantined": 1,
  "conflicting_rows_quarantined": 2,
  "segments": 2,
  "median_dt_s": 0.019998999999984335,
  "missing_xyz": {
    "x": 0,
    "y": 0,
    "z": 0
  },
  "time_min_s": 5.7e-05,
  "time_max_s": 179.985746
}
Estados play: {'In': 6547, 'Out': 2452}
Estados bounds: {'In': 8942, 'Out': 57}
       t        x         y        z  speed_provider_mps
0.000057 0.035830 -0.029369 0.192403            0.171502
0.020029 0.415892 -0.022034 0.203925           19.042010
0.040053 0.849265 -0.014419 0.205506           21.646151
```

Código 4 Construcción causal de características

La rapidez máxima y los cambios extremos se reportan como señales de revisión. Este bloque no aplica un umbral de exclusión ni valida automáticamente la plausibilidad física.

```
PITCH_LENGTH_M, PITCH_WIDTH_M = 105.0, 68.0  # provisionales
def add_ball_features(data):
    f = data.copy()
    groups = f.groupby('segment',sort=False)
    local_dt = groups.t.diff()
    for axis in ('x','y','z'):
        f['v'+axis] = groups[axis].diff()/local_dt
```

```
    f['speed_planar'] = np.hypot(f.vx,f.vy)
    f['accel_planar'] = f.groupby('segment').speed_planar.diff()/local_dt
    f['heading_valid'] = f.speed_planar.gt(0.1).astype('float64')
    denom = f.speed_planar.where(f.heading_valid.eq(1))
    f['heading_sin'], f['heading_cos'] = f.vy/denom, f.vx/denom
    lag = 10  # 0.2 s a 50 Hz
    lag_dt = f.t-groups.t.shift(lag)
                                                        f['disp_0p2'] =
np.hypot(f.x-groups.x.shift(lag),f.y-groups.y.shift(lag)).where(lag_dt.between(0.19,0.21))
    f['center_distance'] = np.hypot(f.x,f.y)
    f['x_relative'], f['y_relative'] = f.x/(PITCH_LENGTH_M/2), f.y/(PITCH_WIDTH_M/2)
    for original,new in [('play','in_play'),('bounds','in_bounds')]:
        f[new] = f[original].map({'In':1.0,'Out':0.0})
        f[new+'_known'] = f[original].isin(['In','Out']).astype(float)
    team_side = {lineups[s]['teamId']:s for s in ('home','away')}
    f['possession_side'] = f.possession_team_id.map(team_side).fillna('unknown')
    f['known_possession'] = f.possession_side.ne('unknown').astype(float)
    previous = groups.possession_team_id.shift()
    known = f.possession_team_id.isin(team_side) & previous.isin(team_side)
                                                        f['possession_change'] =
f.possession_team_id.ne(previous).astype(float).where(known)
    third = PITCH_LENGTH_M/6
                            f['ball_zone'] = np.select([f.x < -third,f.x >
third],['negative_x','positive_x'],default='central')
    f.loc[f.x.isna(),'ball_zone'] = 'unknown'
    return f
features = add_ball_features(ball)
print(features[['t','speed_planar','accel_planar','disp_0p2','center_distance','heading_valid','
possession_side']].head(12).to_string(index=False))
print('Rapidez planar, percentiles de la
muestra:',features.speed_planar.quantile([.5,.9,.99]).round(3).to_dict())
print('Rapidez máxima observada del
balón:',round(float(features.speed_planar.max()),3),'m/s; no interpretada como capacidad
de jugador.')
```

Salida de la ejecución del código 4

```
        t  speed_planar  accel_planar  disp_0p2  center_distance  heading_valid
possession_side
0.000057          NaN           NaN       NaN        0.046329            0.0
home
0.020029    19.033269           NaN       NaN        0.416475            1.0
home
0.040053    21.646007    130.480318       NaN        0.849387            1.0
home
0.060050    21.837867      9.594469       NaN        1.285910            1.0
home
0.080049    21.709877     -6.399841       NaN        1.720001            1.0
home
0.100049    21.605770     -5.205348       NaN        2.152078            1.0
home
0.120014    21.543183     -3.134833       NaN        2.582133            1.0
home
0.140014     0.000000  -1077.159140       NaN        2.582133            0.0
home
```

```
0.160046     42.146173   2103.942351       NaN        3.426278          1.0          home
0.180045     20.503532  -1082.186165       NaN        3.836250          1.0          home
0.200008     20.087593    -20.835518  4.201914        4.237181          1.0          home
0.220041     19.805961    -14.058379  4.218553        4.633929          1.0          home
```

Rapidez planar, percentiles de la muestra: {0.5: 3.548, 0.9: 14.375, 0.99: 23.064}
Rapidez máxima observada del balón: 367.046 m/s; no interpretada como capacidad de jugador.

Código 5 Codificación y separación temporal

```
role_levels = ['Goalkeeper','Defender','Midfielder','Forward','Unknown']
role = roster.role_label.where(roster.role_label.isin(role_levels),'Unknown')
roster_encoded = pd.concat([roster[['entity_id','team_id','starter']],
    pd.get_dummies(pd.Categorical(role,categories=role_levels),prefix='role',dtype=float),

pd.get_dummies(pd.Categorical(roster.side,categories=['home','away']),prefix='side',dtype
=float)],axis=1)
start,end = features.t.min(),features.t.max()
cut1,cut2 = start+.6*(end-start),start+.8*(end-start)
split = np.select([features.t<=cut1,
                   (features.t>cut1+GUARD_S)&(features.t<=cut2),
                   features.t>cut2+GUARD_S],['train','validation','test'],default='guard')
features['split'] = split
print('Codificación de roles:')
print(roster_encoded.drop(columns=['entity_id','team_id']).head(3).to_string(index=False)
)
print('Separación:',features.split.value_counts().to_dict())
assert all((features.split==s).sum()>20 for s in ('train','validation','test'))
print('Rango temporal por bloque:')
print(features.groupby('split').t.agg(['min','max','count']).to_string())
```

Salida de la ejecución del código 5

Codificación de roles:

```
 starter  role_Goalkeeper  role_Defender  role_Midfielder  role_Forward  role_Unknown
side_home  side_away
    True             1.0            0.0              0.0           0.0           0.0
    True             0.0            1.0              0.0           0.0           0.0
    True             0.0            1.0              0.0           0.0           0.0
```

Separación: {'train': 5401, 'test': 1750, 'validation': 1747, 'guard': 101}
Rango temporal por bloque:

```
                min         max  count
split
guard       108.011462  144.988527    101
test        145.008521  179.985746   1750
train         0.000057  107.991439   5401
validation  109.011380  143.968610   1747
```

Código 6 Transformación y escalamiento

```
train_mask = features.split.eq('train')
train_disp = features.loc[train_mask,'disp_0p2'].dropna()
skew_before,skew_log = float(train_disp.skew()),float(np.log1p(train_disp).skew())
use_log = abs(skew_before)>1 and abs(skew_log)<abs(skew_before)
features['disp_feature'] = np.log1p(features.disp_0p2) if use_log else features.disp_0p2
continuous = ['x_relative','y_relative','z','vx','vy','vz','speed_planar','speed_provider_mps',
              'accel_planar','disp_feature','center_distance','heading_sin','heading_cos']
binary = ['heading_valid','known_possession','possession_change','in_play','in_play_known','in_bounds','in_bounds_known']
numeric = features[continuous+binary].replace([np.inf,-np.inf],np.nan).copy()
missing_masks = numeric[continuous].isna().astype(float).add_suffix('_missing')
medians = numeric.loc[train_mask].median().fillna(0.0)
filled = numeric.fillna(medians)
mu = filled.loc[train_mask,continuous].mean()
sigma = filled.loc[train_mask,continuous].std(ddof=0)
scaled = filled.copy()
scaled[continuous] = (filled[continuous]-mu)/sigma.where(sigma>1e-12,1.0)
categories = pd.concat([

pd.get_dummies(pd.Categorical(features.possession_side,categories=['home','away','unknown']),prefix='possession',dtype=float),

pd.get_dummies(pd.Categorical(features.ball_zone,categories=['negative_x','central','positive_x','unknown']),prefix='zone',dtype=float)
],axis=1)
X = pd.concat([scaled,missing_masks,categories],axis=1)
assert np.isfinite(X.to_numpy()).all()
print('Asimetría desplazamiento:',round(skew_before,4),'| log1p:',round(skew_log,4),'| aplicada:',use_log)
print('Media y desviación tras escalamiento (entrenamiento):')
print(X.loc[train_mask,continuous].agg(['mean','std']).round(4).to_string())
print('Matriz candidata:',X.shape)
```

Salida de la ejecución del código 6

```
Asimetría desplazamiento: 0.966 | log1p: 0.2243 | aplicada: False
Media y desviación tras escalamiento (entrenamiento):
      x_relative  y_relative       z      vx      vy      vz  speed_planar  speed_provider_mps  accel_planar  disp_feature  center_distance  heading_sin  heading_cos
mean     -0.0000      0.0000  0.0000  0.0000  0.0000  0.0000       -0.0000             -0.0000       -0.0000        0.0000          -0.0000       0.0000      -0.0000
std       1.0001      1.0001  1.0001  1.0001  1.0001  1.0001        1.0001              1.0001        1.0001        1.0001           1.0001       1.0001       1.0001
```

Matriz candidata: (8999, 40)

Código 7 Filtrado y extracción por PCA

```
variances = X.loc[train_mask].var(ddof=0)
constant = variances.index[variances<=1e-12].tolist()
varying = [c for c in X if c not in constant]
corr = X.loc[train_mask,varying].corr().abs()
kept,dropped_pairs = [],[]
for col in varying:
    redundant = next((c for c in kept if corr.loc[c,col]>=.95),None)
    if redundant is None:
        kept.append(col)
    else:

dropped_pairs.append({'removed':col,'kept':redundant,'abs_r':float(corr.loc[redundant,col]
)})
X_filtered = X[kept]
pca_cols = [c for c in kept if c in continuous]
A = X.loc[train_mask,pca_cols].to_numpy()
pca_center = A.mean(axis=0)
U,S,Vt = np.linalg.svd(A-pca_center,full_matrices=False)
ratio = S**2/np.sum(S**2)
k = int(np.searchsorted(np.cumsum(ratio),.95)+1)
components = Vt[:k]
Z = (X[pca_cols].to_numpy()-pca_center)@components.T
reconstruction = Z@components+pca_center
mse                                                
```

Salida de la ejecución del código 7

Constantes excluidas: ['in_play_known', 'in_bounds_known', 'x_relative_missing', 'y_relative_missing', 'z_missing', 'speed_provider_mps_missing', 'center_distance_missing', 'zone_unknown']
Correlaciones que motivan exclusión:

removed	kept	abs_r
vy_missing	vx_missing	1.000000
vz_missing	vx_missing	1.000000
speed_planar_missing	vx_missing	1.000000
heading_sin_missing	heading_valid	1.000000
heading_cos_missing	heading_valid	1.000000
possession_away	possession_home	0.991879
possession_unknown	known_possession	1.000000

Dimensiones: candidatas 40 -> filtradas 25
PCA continuas: 13 -> 10 | varianza acumulada: 0.96186
MSE reconstrucción en espacio estandarizado: {'train': 0.03813713453826381, 'validation': 0.07359734259080107, 'test': 0.090910159549311}
Coeficientes de los componentes PCA:

	x_relative	y_relative	z	vx	vy	vz	speed_planar	speed_provider_mps	accel_planar	disp_feature	center_distance	heading_sin	heading_cos
PC1	-0.225	-0.212	-0.243	0.172	0.063	0.028	-0.496	-0.398	-0.188	-0.478	0.370	0.072	-0.028
PC2	-0.066	-0.169	0.115	-0.498	-0.466	-0.159	0.039	-0.116	0.185	-0.132	0.162	-0.424	-0.437
PC3	-0.293	-0.184	-0.036	-0.311	0.453	-0.251	0.265	0.032	0.325	0.052	0.299	0.473	-0.143
PC4	0.257	0.517	-0.536	-0.128	0.048	-0.214	0.074	-0.436	0.236	-0.097	-0.220	0.031	-0.068
PC5	-0.393	0.046	-0.184	0.260	-0.242	-0.013	0.294	-0.092	0.349	0.117	0.308	-0.292	0.523
PC6	-0.364	0.377	-0.187	-0.096	-0.017	0.551	0.090	-0.041	-0.287	0.331	0.204	0.026	-0.365
PC7	-0.344	0.262	0.129	-0.041	-0.030	-0.690	-0.103	-0.041	-0.497	0.225	-0.027	-0.048	0.074
PC8	0.403	-0.331	-0.575	-0.006	-0.023	-0.164	0.100	0.249	-0.296	0.286	0.339	-0.115	-0.025
PC9	-0.166	0.337	-0.238	0.010	-0.107	-0.089	-0.207	0.747	0.150	-0.389	0.047	0.024	-0.075
PC10	0.293	0.276	0.310	0.502	0.044	-0.177	-0.102	-0.036	0.249	0.172	0.463	-0.028	-0.371

Bytes de matrices NumPy (mismos registros, float64): {'candidata': 2879680, 'filtrada': 1799800, 'continuas_pca_entrada': 935896, 'continuas_pca_salida': 719920}

Código 8 Constructor de grafos y adaptación al seguimiento

La rama opcional comprueba frecuencia declarada y evita escoger el último frame de un lote que podría estar truncado. Estos controles están implementados, pero no se verificaron empíricamente con jugadores. La lectura acotada no garantiza cobertura de 22 jugadores ni continuidad del partido completo.

```
def causal_tracking_kinematics(table, hz=25):
    required = {'entity_type','entity_id','period','match_time_s','frame','x','y','team_id','role_label'}
    missing = required-set(table.columns)
    if missing:
        raise ValueError('Faltan columnas del esquema de tracking: '+str(sorted(missing)))
    if not np.isfinite(hz) or hz <= 0:
        raise ValueError('La frecuencia debe ser positiva y confirmada para el archivo.')
    t = table.loc[table.entity_type.isin(['player','ball'])].copy()
    if t.empty or t[['entity_id','period','frame','match_time_s']].isna().any().any():
        raise ValueError('No hay entidades válidas o faltan claves de identidad/tiempo.')
    if t.duplicated(['period','frame','entity_id']).any():
        raise ValueError('Resolver duplicados de entidad/frame antes de construir grafos.')
    t = t.sort_values(['entity_id','period','match_time_s']).reset_index(drop=True)
    dt = t.match_time_s.diff()
    breaks = t.entity_id.ne(t.entity_id.shift())|t.period.ne(t.period.shift())|dt.le(0)|dt.gt(2.5/hz)
    t['_segment'] = breaks.cumsum()
    groups = t.groupby('_segment',sort=False)
    for axis in ('x','y'):
        # Balón sin media; jugadores con media retrospectiva causal.
        smoothed = groups[axis].transform(lambda x:x.rolling(max(1,round(.2*hz)),min_periods=1).mean())
        position = t[axis].where(t.entity_type.eq('ball'),smoothed)
        t['v'+axis+'_causal'] = position.groupby(t._segment).diff()/groups.match_time_s.diff()
    return t

def make_graph(frame_rows):
    t = frame_rows.sort_values(['entity_type','entity_id']).reset_index(drop=True)
    if t[['period','frame']].drop_duplicates().shape[0]!=1:
        raise ValueError('Un grafo debe contener exactamente un instante y periodo.')
    if t.entity_id.isna().any() or t.entity_id.duplicated().any() or t.entity_type.eq('ball').sum()!=1:
        raise ValueError('Identidad duplicada o ausencia de balón.')
    if not np.isfinite(t[['x','y']].astype(float).to_numpy()).all():
        raise ValueError('Posiciones faltantes: no inventar geometría.')
    numeric = t[['x','y','vx_causal','vy_causal']].astype(float).copy()
    numeric[['vx_causal','vy_causal']] = numeric[['vx_causal','vy_causal']].replace([np.inf,-np.inf],np.nan)
```

```
    motion_known = numeric[['vx_causal','vy_causal']].notna().all(axis=1).astype(float)
    numeric['x']/=PITCH_LENGTH_M/2
    numeric['y']/=PITCH_WIDTH_M/2
    role = t.role_label.where(t.role_label.isin(role_levels),'Unknown')
                                                                role_onehot =
pd.get_dummies(pd.Categorical(role,categories=role_levels),prefix='role',dtype=float).to_
numpy()
    nodes = np.column_stack([numeric.fillna(0).to_numpy(),motion_known,
        t.entity_type.eq('ball').astype(float).to_numpy(),role_onehot])
    n = len(t)
    src,dst = np.where(~np.eye(n,dtype=bool))
                                                        positions,velocity =
numeric[['x','y']].to_numpy(),numeric[['vx_causal','vy_causal']].fillna(0).to_numpy()
    relative = positions[dst]-positions[src]
                                                            distance =
np.hypot(t.x.to_numpy()[dst]-t.x.to_numpy()[src],t.y.to_numpy()[dst]-t.y.to_numpy()[src]
)/PITCH_LENGTH_M
    teams = t.team_id.to_numpy()
            same = np.array([float(pd.notna(teams[i]) and pd.notna(teams[j]) and
teams[i]==teams[j]) for i,j in zip(src,dst)])
                                                            ball_edge =
(t.entity_type.eq('ball').to_numpy()[src]|t.entity_type.eq('ball').to_numpy()[dst]).astype(fl
oat)
                                                    edge_motion_known =
motion_known.to_numpy()[src]*motion_known.to_numpy()[dst]
                                                                attrs =
np.column_stack([relative,velocity[dst]-velocity[src],distance,same,ball_edge,edge_motion
_known])
    graph = {'node_ids':t.entity_id.astype(str).tolist(),'x':nodes.astype('float32'),
       'edge_index':np.vstack([src,dst]).astype('int64'),'edge_attr':attrs.astype('float32'),
       'period':int(t.period.iloc[0]),'frame':int(t.frame.iloc[0]),

'node_features':['x_relative','y_relative','vx_causal','vy_causal','motion_known','is_ball']+['r
ole_'+r for r in role_levels],

'edge_features':['dx_relative','dy_relative','dvx','dvy','distance_relative','same_team','involv
es_ball','motion_known'],
          'possession_team_id':str(t.possession_team_id.iloc[0]) if 'possession_team_id' in t
else None}
          assert graph['edge_index'].shape==(2,n*(n-1)) and np.isfinite(nodes).all() and
np.isfinite(attrs).all()
    return graph

tracking_path = os.environ.get('AVANCE2_TRACKING_PARQUET')
graph_status = 'PENDIENTE: no se proporcionó el Parquet de jugadores; constructor
definido, sin grafo colectivo ejecutado.'
```

```
if tracking_path:
    import pyarrow.parquet as pq
    parquet = pq.ParquetFile(tracking_path)
    # Lectura acotada: hasta 20 000 filas, no todo el partido.
    batch = next(parquet.iter_batches(batch_size=20000))
    metadata = parquet.schema_arrow.metadata or {}
     match_meta = json.loads(metadata[b'match_meta']) if b'match_meta' in metadata else
{}
    configured_hz = os.environ.get('AVANCE2_TRACKING_HZ')
    hz_value = configured_hz or match_meta.get('sampling_hz')
    if hz_value is None:
            raise ValueError('Confirme la frecuencia y configure AVANCE2_TRACKING_HZ; no
inferirla de meta.json de otro partido.')
    tracking = causal_tracking_kinematics(batch.to_pandas(),hz=float(hz_value))
    # El lote puede terminar a mitad de un frame: excluir su última clave.
    last_key = tracking[['period','frame']].sort_values(['period','frame']).iloc[-1]
                                                                    tracking =
tracking.loc[~(tracking.period.eq(last_key.period)&tracking.frame.eq(last_key.frame))]
                counts = tracking.groupby(['period','frame']).entity_type.agg(lambda x:
{'player','ball'}.issubset(set(x)))
    if not counts.any():
        raise ValueError('No hay un instante con balón y jugadores en el lote acotado.')
    period,frame = counts[counts].index[-1]
                                                                    graph =
make_graph(tracking.loc[tracking.period.eq(period)&tracking.frame.eq(frame)])

np.savez_compressed(OUT/'grafo_real.npz',x=graph['x'],edge_index=graph['edge_index'],
edge_attr=graph['edge_attr'])
                    graph_status = f"EJECUTADO: {len(graph['node_ids'])} nodos,
{graph['edge_index'].shape[1]} aristas del Parquet configurado."
print(graph_status)
```

Salida de la ejecución del código 8

PENDIENTE: no se proporcionó el Parquet de jugadores; constructor definido, sin grafo colectivo ejecutado.

Código 9 Verificación y exportación de resultados

```
prefix = ball.iloc[:min(1000,len(ball))].copy()
prefix_features = add_ball_features(prefix)
check_cols                                                                    =
['vx','vy','vz','speed_planar','accel_planar','disp_0p2','heading_sin','heading_cos','possession
_change']
np.testing.assert_allclose(prefix_features[check_cols].to_numpy(),features.iloc[:len(prefix)
][check_cols].to_numpy(),equal_nan=True)
np.testing.assert_allclose(components@components.T,np.eye(k),atol=1e-10)
```

```
eig = np.linalg.eigvalsh(np.cov((A-pca_center).T))[::-1]
np.testing.assert_allclose(eig,S**2/(len(A)-1),rtol=1e-7,atol=1e-10)
assert X.loc[features.split.eq('train')].shape[0] != len(X)
params =
{'match':MATCH,'sources':provenance,'members':selected_members,'quality':quality,
    'provisional_pitch_m':[PITCH_LENGTH_M,PITCH_WIDTH_M],'max_gap_s':MAX_GAP_S,
          'cinematic_quality_status':'PENDIENTE: revisar rapidez y cambios extremos;
escalamiento y PCA provisionales.',
    'split_cut_s':[float(cut1),float(cut2)],'guard_s':GUARD_S,

'continuous':continuous,'medians':medians.to_dict(),'means':mu.to_dict(),'std':sigma.to_di
ct(),
    'log_disp_applied':bool(use_log),'skew_before':skew_before,'skew_log':skew_log,

'constant_removed':constant,'correlation_threshold':.95,'correlation_removed':dropped_pai
rs,
    'filtered_features':kept,'pca_columns':pca_cols,'pca_center':pca_center.tolist(),
    'pca_components':components.tolist(),'pca_variance_ratio':ratio[:k].tolist(),
    'pca_k':k,'reconstruction_mse':mse,'graph_status':graph_status,

'versions':{'python':platform.python_version(),'numpy':np.__version__,'pandas':pd.__versi
on__}}
(OUT/'parametros_y_resultados.json').write_text(json.dumps(params,ensure_ascii=False,i
ndent=2,allow_nan=False),encoding='utf-8')
features.to_csv(OUT/'caracteristicas_balon.csv',index=False)
X_filtered.assign(split=features.split).to_csv(OUT/'matriz_filtrada.csv',index=False)
pd.DataFrame(Z,columns=[f'PC{i+1}' for i in
range(k)]).assign(split=features.split).to_csv(OUT/'componentes_pca.csv',index=False)
print('Verificaciones: causalidad por truncamiento, PCA y matrices finitas: OK.')
print('Salidas:',sorted(p.name for p in OUT.iterdir() if p.is_file()))
print('Resumen: registros',len(features),'| variables continuas utilizadas',len(continuous),'|
matriz',X.shape[1],
     '| filtradas',len(kept),'| componentes',k,'| grafo colectivo:',bool(tracking_path))
```

Salida de la ejecución del código 9

```
Verificaciones: causalidad por truncamiento, PCA y matrices finitas: OK.
Salidas: ['caracteristicas_balon.csv', 'componentes_pca.csv',
'duplicados_en_cuarentena.csv', 'matriz_filtrada.csv', 'parametros_y_resultados.json']
Resumen: registros 8999 | variables continuas utilizadas 13 | matriz 40 | filtradas 25 |
componentes 10 | grafo colectivo: False
```

Anexo B Trazabilidad y controles pendientes

Este anexo conserva la evidencia complementaria necesaria para interpretar y reproducir el avance. El inventario del visualizador, las copias descargadas y la revisión de su interfaz permanecen como documentación interna, sin incorporarse al informe de ingeniería de características.

Fuentes procesadas

Tabla 19. Archivos fuente, tamaño y uso

Archivo	Tamaño en bytes	Uso
matchLineups.json	49,178	Identidad de equipos y jugadores
2026-08-22_GENOA-NAPOLI_scrubbed_ball_NOT_PARSED.zip	109,396,388	Muestra de seguimiento del balón

Fuente: Elaboración propia.

matchLineups.json

SHA-256: daade4d82904fcbe27b5b429744d9d82c1b03063b0ec64453dc46e9acab0a6d1
2026-08-22_GENOA-NAPOLI_scrubbed_ball_NOT_PARSED.zip

SHA-256: 710a8aacb16676fcdca97afe57ec4ea16fe0f793a45cb87629d6d72a8eebbae4
Las huellas permiten reconocer archivos idénticos byte a byte. No validan las unidades, la correspondencia temporal o el significado de los campos.

Archivos generados

Tabla 20. Contenido de los archivos de resultados

Archivo	Contenido
caracteristicas_balon.csv	Características y bloques temporales antes de completar los faltantes.
matriz_filtrada.csv	25 atributos procesados y la columna de identificación split.
componentes_pca.csv	10 componentes continuos y la columna de identificación split.
duplicados_en_cuarentena.csv	Dos observaciones distintas que colisionaron en una clave redondeada.
parametros_y_resultados.json	Fuentes, configuración, parámetros, decisiones, comprobaciones y versiones.

Fuente: Elaboración propia.

La carpeta resultados_revision_anexos separa estas salidas de las originales. La columna split es un identificador de partición y no una característica de entrada: por ello, el CSV filtrado tiene 26 columnas físicas y el CSV de componentes tiene 11, aunque sus matrices de atributos tengan 25 y 10 respectivamente.

Controles pendientes y efecto sobre la preparación

Tabla 21. Controles pendientes y acciones requeridas

Control pendiente	Consecuencia y acción requerida
Extremos de rapidez y cambio de rapidez	Localizar observaciones, revisar tiempos y posiciones y justificar su tratamiento. Repetir FE, escalamiento y PCA si cambia la muestra.
Dimensiones y sistema de coordenadas	Confirmar origen, ejes y tamaño del campo; revisar distancias relativas y zonas.
Reloj entre periodos	Validar la reconstrucción temporal en el partido completo antes de formar episodios.
Significado de play bounds y posesión	Consultar la documentación del proveedor; no equiparar posesión de equipo con control individual.
Seguimiento de jugadores	Comprobar identidad, frecuencia, presencia de entidades y ejecutar el constructor de grafos.
Evaluación predictiva	Acordar etiquetas, tarea y horizonte; utilizar partidos separados y comparar representaciones.

Fuente: Elaboración propia.

Resultado que puede afirmarse

Se ejecutó una demostración de preparación sobre una muestra real de balón. Se comprobaron propiedades numéricas y causalidad de las características examinadas en un prefijo. No se entrenó una GNN ni se midió precisión de jugadas, convergencia o tiempo de entrenamiento. La compresión PCA no se interpreta como identificación de patrones tácticos.

Conclusiones generales

En esta actividad desarrollamos un proceso de ingeniería de características para preparar los datos de seguimiento de un partido de fútbol, tomando como caso de estudio una muestra del encuentro entre Genoa y Napoli. El objetivo fue transformar los registros originales de posición y movimiento del balón en un conjunto de variables que permitiera representar mejor su comportamiento y que pudiera utilizarse posteriormente en modelos de aprendizaje automático.

A partir de los datos disponibles, construimos características relacionadas con la velocidad, aceleración, dirección y desplazamiento del balón, además de incorporar información espacial, temporal y contextual. Posteriormente, aplicamos técnicas de codificación, escalamiento y selección de características para mejorar la representación de los datos y reducir la redundancia entre variables.

Uno de los principales resultados fue la reducción de 40 a 25 características mediante filtros de varianza y correlación. Adicionalmente, aplicamos Análisis de Componentes Principales (PCA) sobre 13 variables continuas, obteniendo 10 componentes que conservan aproximadamente el 96.19 % de la varianza original. Estos resultados muestran que es posible reducir la dimensionalidad de la información sin perder una proporción considerable de su variabilidad, aunque todavía será necesario evaluar cómo afecta esta transformación al desempeño de los futuros modelos predictivos.

También desarrollamos una primera implementación para construir representaciones en grafos, considerando las características de los jugadores y las relaciones espaciales entre ellos. Sin embargo, debido a que todavía no contamos con los datos completos de seguimiento de jugadores, esta implementación no pudo validarse con un grafo colectivo real. Por lo tanto, reconocemos esta limitación como parte del alcance actual del proyecto.

Desde la perspectiva de CRISP-ML(Q), consideramos que esta actividad permitió establecer una base reproducible para la preparación de datos, documentando las transformaciones realizadas y las decisiones tomadas durante el proceso. No obstante, identificamos como trabajo pendiente la revisión de velocidades y aceleraciones extremas, así como la validación de las características generadas con conjuntos de datos adicionales.

En conclusión, **este avance representa una primera etapa para pasar de los datos originales de seguimiento a una representación estructurada del comportamiento del balón**. El siguiente paso será extender este procedimiento a los jugadores y validar la construcción de grafos, con el propósito de desarrollar posteriormente modelos capaces de analizar movimientos colectivos y anticipar el desarrollo de situaciones tácticas durante un partido.